



UNIVERSITÀ DEGLI STUDI DI CAGLIARI

FACOLTÀ DI SCIENZE

Corso di Laurea Triennale in

Informatica Applicata e Data Analytics

Adattamento e validazione di una
pipeline di rilevamento di anomalie per
dati radioastronomici SETI del Sardinia
Radio Telescope

Relatori:

Dott.ssa Maria Ilaria Lunesu

Dott. Andrea Pinna

Dott.ssa Maura Pilia

Candidato:

Davide Deplano

matr. 60/79/00212

Anno Accademico 2025/2026

Cagliari - 24/07/2026

Indice

Introduzione	3
1 Contesto scientifico	6
1.1 SETI e tecnosignature	6
1.2 Sardinia Radio Telescope	9
1.3 Il progetto Breakthrough Listen	10
1.4 Approcci di machine learning alla ricerca SETI	11
1.5 UMAP Reverse Search	13
2 Anomaly detection applicato al SETI	17
2.1 Architettura generale della pipeline	18
2.2 Architettura del sistema implementato	20
2.3 Dati	23
2.3.1 Dati simulati	24
2.3.2 Dati reali del SRT	26
2.3.3 Differenze rispetto al setting originale	27
2.4 Estrattore di feature di cross-correlazione	28
2.4.1 L'estrattore di Pardo e il suo limite strutturale	28
2.4.2 Definizione di NCC-max	29
2.4.3 Validazione: test di iniezione controllata	30
2.5 Density Filter	33
2.5.1 Descrizione del filtro nel lavoro di Pardo et al.	33
2.5.2 Soglia adattiva	34
2.5.3 Selezione degli iperparametri UMAP	34
2.5.4 Risultati sui dati del SRT	39

2.6	Frequency Filter	40
2.6.1	Descrizione del filtro nel lavoro di Pardo et al.	40
2.6.2	Ricalibrazione del numero di componenti	41
2.6.3	Risultati sui dati del SRT	41
2.7	Similarity Filter	43
2.7.1	Descrizione del filtro nel lavoro di Pardo et al.	43
2.7.2	Rappresentazione <code>cadence_raw</code>	44
2.7.3	Verifica della sensibilità	44
2.7.4	Risultati sui dati del SRT	45
2.8	Ranking	48
3	Applicazione autoencoder ai dati SETI	50
3.1	Motivazione	50
3.2	Architettura del modello	51
3.3	Addestramento	53
3.4	Punteggio di anomalia	54
3.5	Risultati	55
4	Confronto tra modello originale e modello proposto	59
4.1	Impostazione del confronto	59
4.2	Confronto dei pool promossi	60
4.3	Confronto dei risultati Frequency e Similarity	61
4.4	Confronto dei campioni di ranking	63
4.5	Discussione	65
5	Conclusione e sviluppi futuri	68
5.1	Riepilogo del lavoro	68
5.2	Limitazioni	69
5.3	Sviluppi futuri	70
	Bibliografia	73
	Ringraziamenti	75

Introduzione

La ricerca di segnali di origine artificiale nelle osservazioni radioastronomiche rappresenta uno dei temi più affascinanti, stimolanti e complessi dell’astrofisica moderna. Nel contesto del programma SETI (Search for Extraterrestrial Intelligence), particolare attenzione è rivolta ad identificare possibili tecnosignature, ovvero segnali riconducibili alla presenza di civiltà tecnologicamente avanzate. Il lavoro di tesi si colloca in questo filone di ricerca e trae le sue origini dall’attività svolta durante il tirocinio condotto in collaborazione con l’osservatorio astronomico e l’Università di Berkeley. A differenza di altri filoni di ricerca astrofisica, la sfida principale non risiede soltanto nella sensibilità strumentale, ma nella capacità di distinguere segnali potenzialmente artificiali da fenomeni naturali e da interferenze di origine terrestre. Con l’aumento esponenziale della quantità di dati prodotti dai radiotelescopi moderni l’analisi manuale è divenuta impraticabile, e la selezione automatica dei candidati si è affermata come una componente irrinunciabile dei moderni programmi osservativi SETI.

Il presente lavoro si colloca in questo contesto e ha per oggetto l’applicazione di una pipeline di anomaly detection ai dati del Sardinia Radio Telescope (SRT). La pipeline di riferimento, sviluppata da Pardo et al. (2025) [1] nell’ambito del programma Breakthrough Listen e calibrata sui dati del Green Bank Telescope, costituisce lo stato dell’arte nella riduzione automatica dello spazio di ricerca SETI. Il SRT rappresenta un contesto osservativo strutturalmente differente da quello originale, sia per le bande operative impiegate — la banda C (4,2–7,7 GHz) e la banda K (18–26,5 GHz), entrambe più alte di quelle utilizzate da Pardo et al. — sia per il fatto che il SRT non è attualmente integrato in un programma osservativo SETI sistematico. La trasferibilità di una pipeline calibrata su un altro strumento e su altre bande osservative non è quindi un fatto acquisito, ma una

proprietà da verificare sperimentalmente.

Il valore di un'operazione di questo tipo non si esaurisce nell'applicazione a uno specifico strumento. La ricerca SETI è tanto più efficace quanto più estesa è la copertura del cielo e quanto più diversificati sono i regimi spettrali osservati, e ogni nuovo radiotelescopio integrato in una rete osservativa contribuisce ad ampliare entrambe le dimensioni. Affinché questa integrazione sia praticabile su scala ampia, è necessario che le metodologie di analisi sviluppate per uno strumento siano trasferibili ad altri senza dover ricostruire ogni volta l'intera pipeline da zero. Verificare la trasferibilità di una pipeline esistente, identificarne i punti di fragilità rispetto a un contesto osservativo nuovo e proporre adattamenti architetturali mirati è perciò un contributo che ha valore al di là del singolo caso applicativo: è un passo del processo più ampio di costruzione di una metodologia condivisa per la ricerca SETI multi-strumento. In questa prospettiva, la posizione del SRT è particolarmente favorevole: le sue bande operative C e K coprono regimi spettrali complementari a quelli storicamente impiegati nei programmi di Breakthrough Listen su GBT e Parkes, e la sua integrazione futura in una rete osservativa SETI potrebbe estendere significativamente lo spazio di parametri attualmente esplorato.

I contributi di ricerca di questa tesi sono due. Il primo è la riproduzione end-to-end della pipeline di Pardo et al. a partire dalla sola descrizione testuale del paper, senza alcun codice ereditato dagli autori. La riproduzione è stata realizzata in Python con architettura modulare, ricostruendo fedelmente i moduli per cui la descrizione è sufficientemente dettagliata — estrazione delle feature, generazione del dataset sintetico, costruzione dei modelli statistici, calcolo dei punteggi — e introducendo assunzioni esplicite dove la descrizione lascia margini di interpretazione. Il secondo contributo è l'identificazione di tre limiti architetturali della pipeline originale e l'implementazione di altrettante modifiche mirate a superarli, ciascuna giustificata da considerazioni metodologiche e validata sperimentalmente: un nuovo estrattore di feature, denominato NCC-max, che generalizza la correlazione di Pearson a lag zero usata nel paper a una cross-correlazione tollerante a piccoli spostamenti, in modo da riconoscere i segnali che derivano in frequenza tra osservazioni successive; il calcolo adattivo della soglia di promozione del filtro di densità, che nel lavoro originale è un valore fisso calibrato sui dati di un altro strumento e quindi non

trasferibile; un filtro alternativo di prima scrematura basato su autoencoder, proposto come complemento al filtro di densità e calibrato direttamente sui dati osservativi del SRT.

La riproduzione end-to-end della pipeline a partire dalla sola descrizione testuale del paper, senza alcun codice ereditato dagli autori, ha imposto una disciplina metodologica esplicita: ogni componente è stata ricostruita sulla base della descrizione del lavoro originale, documentando le assunzioni introdotte nei punti in cui la descrizione lascia margini di interpretazione, in modo che le scelte fatte siano tracciabili e discutibili. Allo stesso tempo, una limitazione del lavoro va riconosciuta apertamente: la mancanza del dataset di addestramento di Pardo et al. e dell'insieme di candidati reali da loro analizzati ha impedito una validazione comparativa diretta della presente implementazione contro la loro. La verifica delle scelte è stata pertanto condotta in modo indipendente, attraverso un test di iniezione controllata su una cadenza reale del SRT, l'analisi statistica dei risultati prodotti sui dati osservativi e il confronto interno tra varianti alternative degli stessi moduli. I risultati ottenuti vanno quindi interpretati come valutazione dell'applicabilità della pipeline al SRT nel contesto del presente lavoro, e non come confronto quantitativo diretto con i risultati ottenuti dagli autori sui dati del Green Bank Telescope.

La tesi è organizzata come segue. Il Capitolo 1 descrive il contesto scientifico, lo strumento osservativo, il programma Breakthrough Listen e i principali approcci di apprendimento automatico applicati alla ricerca SETI, motivando la scelta del riferimento metodologico adottato. Il Capitolo 2 presenta la pipeline di Pardo et al. insieme alle modifiche architetturali introdotte per i dati del SRT, modulo per modulo, in un'unica esposizione integrata; al suo interno sono discussi anche il dataset di addestramento, i dati osservativi del SRT e la validazione sperimentale tramite test di iniezione controllata. Il Capitolo 3 è dedicato al filtro basato su autoencoder, dalla motivazione architetturale fino alla calibrazione sui dati reali. Il Capitolo 4 confronta i due workflow alternativi — quello fondato sul filtro di densità originale e quello fondato sul filtro autoencoder — sui medesimi candidati del SRT. Il Capitolo 5 riassume i risultati ottenuti, le limitazioni del lavoro e i possibili sviluppi futuri.

Capitolo 1

Contesto scientifico

Questo capitolo introduce il contesto in cui si colloca il lavoro. La Sezione 1.1 presenta la ricerca SETI (Search for Extraterrestrial Intelligence) e il concetto di tecnosignature, dalle origini storiche fino all'attuale impiego sistematico di tecniche di Machine Learning per la selezione automatica dei candidati. La Sezione 1.2 descrive il Sardinia Radio Telescope, da cui provengono i dati analizzati, le bande osservative utilizzate (C e K) e le specifiche tecniche delle cadenze su cui opera la pipeline. La Sezione 1.3 introduce il programma Breakthrough Listen, da cui il tirocinio e la tesi hanno avuto origine, i dati di confronto e i suggerimenti operativi, e nell'ambito del quale è stata sviluppata la pipeline di anomaly detection di Pardo et al. (2025) [1] adottata come riferimento metodologico. La Sezione 1.4 colloca tale pipeline nel panorama dei lavori che applicano tecniche di apprendimento automatico alla ricerca SETI, motivando la scelta del riferimento adottato. La Sezione 1.5 descrive infine lo strumento di esplorazione interattiva UMAP Reverse Search, sviluppato in questo lavoro come supporto all'analisi dei candidati prodotti dalla pipeline.

1.1 SETI e tecnosignature

La ricerca di intelligenza extraterrestre (SETI, Search for Extraterrestrial Intelligence) si propone di rilevare nell'universo osservabile tracce di civiltà tecnologicamente avanzate attraverso l'analisi di segnali di origine artificiale. I primi tentativi sistematici risalgono agli anni Sessanta, quando le prime osservazioni dedicate erano limitate a pochi bersagli

e a intervalli di frequenza di poche centinaia di Hz. Da allora la capacità osservativa è cresciuta di diversi ordini di grandezza, fino agli attuali programmi che monitorano sistematicamente milioni di stelle su decine di GHz, rendendo necessario lo sviluppo di tecniche automatiche per la selezione dei candidati. In questo ambito si definiscono tecnosignature le manifestazioni fisiche o chimiche riconducibili all'attività tecnologica di una civiltà non umana: esse costituiscono l'oggetto osservativo della ricerca SETI e servono come indicatori che permettono di distinguere un'eventuale sorgente artificiale dai fenomeni naturali noti. In ambito radioastronomico l'attenzione si concentra principalmente su emissioni a banda stretta (narrowband). La motivazione è fisica: i fenomeni astrofisici naturali producono spettri intrinsecamente larghi, distribuiti su intervalli di frequenza dell'ordine dei MHz o più. Una emissione concentrata in pochi Hz non ha controparti naturali note, mentre è tipica della comunicazione e della strumentazione tecnologica umana, che opera, per natura, su intervalli di frequenza molto ristretti. Un segnale di pochi Hz privo di un'origine astrofisica nota potrebbe quindi essere ricondotto a una sorgente artificiale.

Una chiave nella ricerca SETI è la struttura temporale delle osservazioni organizzate in cadenze ON/OFF: il radiotelescopio punta alternatamente verso la stella bersaglio (posizione ON) e verso una posizione di riferimento vicina (posizione OFF). Un segnale di origine artificiale legata alla sorgente bersaglio dovrebbe essere presente nei pannelli ON e assente in quelli OFF, distinguendosi così dall'interferenza radio (RFI), che tipicamente appare in entrambe le posizioni, come illustrato in Figura 1.1. Questa struttura di osservazione è alla base dei metodi automatici di classificazione e filtraggio dei candidati.




Figura 1.1: Esempio di cadenza ON/OFF a 6 pannelli: il segnale narrowband è visibile negli slot ON (pannelli 1, 3, 5) e assente negli slot OFF (pannelli 2, 4, 6), coerentemente con un'emissione legata alla sorgente bersaglio.

Il principale ostacolo alla ricerca SETI non è la sensibilità strumentale dei radiotelescopi moderni, ma la gestione della grande quantità di dati prodotti e la separazione di potenziali tecnosignature dal rumore e dall'RFI di origine terrestre. Per questo motivo, negli ultimi anni sono stati sviluppati approcci basati su Machine Learning per automatizzare la selezione dei candidati e ridurre lo spazio di ricerca a un sottoinsieme statisticamente significativo.

1.2 Sardinia Radio Telescope

Il Sardinia Radio Telescope (SRT, Figura 1.2) [2] è un radiotelescopio a piatto singolo da 64 metri di diametro situato a San Basilio, in provincia di Cagliari. Entrato in operatività scientifica nel 2013, è gestito dall'Istituto Nazionale di Astrofisica (INAF) ed è uno dei radiotelescopi più grandi d'Europa, capace di operare in un ampio intervallo di frequenze che si estende dalla banda L (1.3–1.8 GHz) fino alla banda W (84–116 GHz), grazie a una serie di ricevitori intercambiabili.




Figura 1.2: Sardinia Radio Telescope - San Basilio CA

Nel contesto del presente lavoro, i dati utilizzati provengono da osservazioni condotte nelle bande C (4.2–7.7 GHz) e K (18–26.5 GHz). La scelta non è arbitraria: queste due bande coprono regimi osservativi sufficientemente distanti da rappresentare condizioni di rumore strumentale, occupazione spettrale e tipologie di interferenze radio molto diverse tra loro, e costituiscono, quindi, un banco di prova significativo per valutare la trasferibilità di una pipeline calibrata su un altro strumento. Sono, inoltre, le due bande per cui era disponibile un volume di osservazioni sufficiente a popolare entrambi i regimi di addestramento e inferenza.

La struttura dei dati è quella tipica delle osservazioni SETI: cadenze di sei pannelli alternati ON/OFF su stelle vicine, ciascun pannello corrispondente a circa cinque minuti di osservazione. La risoluzione temporale dei dati è di circa 18,25 secondi per campione, suddivisi in 16 campioni temporali per pannello. La risoluzione spettrale è di circa 2,79 Hz

per canale, valore compatibile con la ricerca di segnali a banda stretta dell'ordine di pochi Hz, oggetto della ricerca SETI in ambito radio. La pipeline opera su finestre spettrali di 4096 canali consecutivi, corrispondenti a circa 11,4 kHz, che costituiscono l'unità di analisi a cui vengono ricondotti i candidati estratti dai file di acquisizione.

A differenza del Green Bank Telescope (GBT) utilizzato nel programma Breakthrough Listen, l'SRT non è ancora integrato in un programma osservativo SETI sistematico. I dati analizzati in questo lavoro rappresentano quindi un contesto osservativo indipendente, con caratteristiche strumentali proprie — risoluzione spettrale, rumore di sistema, livelli di RFI — che rendono necessario un adattamento specifico della pipeline di riferimento.

1.3 Il progetto Breakthrough Listen

Breakthrough Listen [3] è il più grande programma scientifico dedicato alla ricerca di intelligenza extraterrestre mai finanziato, lanciato nel 2015 con un investimento di 100 milioni di dollari nell'arco di dieci anni. Il programma impiega alcuni dei radiotelescopi più potenti al mondo — tra cui il Green Bank Telescope (GBT) in West Virginia e il Parkes Telescope in Australia — per monitorare sistematicamente oltre un milione di stelle vicine, coprendo un intervallo di frequenze da 1 a 93 GHz.

L'obiettivo principale è raccogliere dati radioastronomici sufficientemente dettagliati nel tempo e in frequenza da poter rilevare potenziali tecnosignature di origine artificiale. La mole di dati prodotta è considerevole: ogni sessione osservativa genera centinaia di gigabyte di osservazioni, rendendo l'analisi manuale impraticabile e rendendo necessario l'uso di tecniche automatizzate di Machine Learning per la selezione dei candidati. In particolare, la scarsità di esempi positivi noti — non esistono segnali tecnologici extra-terrestri confermati — impedisce l'impiego di approcci di classificazione supervisionata in senso stretto e orienta naturalmente la scelta verso tecniche di *anomaly detection*, in cui il modello apprende il comportamento tipico dei dati e segnala come potenziali candidati le osservazioni che da esso si discostano.

È nell'ambito di Breakthrough Listen che Pardo et al. (2025) [1] hanno sviluppato la pipeline di anomaly detection che costituisce il riferimento metodologico di questo

lavoro. Gli autori l’hanno progettata e validata sui dati del GBT, ottenendo una riduzione dello spazio di ricerca di circa sette ordini di grandezza — da circa 10^{11} osservazioni iniziali a poche migliaia di candidati selezionati per l’ispezione manuale — e ispezionando complessivamente circa 20.000 candidati, nessuno dei quali si è rivelato compatibile con un segnale di origine tecnologica extraterrestre alla verifica finale. La pipeline rappresenta oggi lo stato dell’arte nella riduzione automatica dello spazio di ricerca SETI. Il presente lavoro¹ si propone di valutarne l’applicabilità a un contesto osservativo differente, quello del Sardinia Radio Telescope.

1.4 Approcci di machine learning alla ricerca SETI

La pipeline di Pardo et al. (2025) [1] si colloca all’interno di una linea di ricerca che, negli ultimi dieci anni, ha esplorato l’applicazione di tecniche automatiche di analisi dei dati al problema della selezione dei candidati SETI. Una rassegna sintetica dei principali approcci aiuta a comprendere le scelte metodologiche che caratterizzano il lavoro di riferimento e che, di conseguenza, orientano anche il presente lavoro.

Il punto di partenza storico è rappresentato dagli approcci non basati su apprendimento automatico, di cui l’esempio più rilevante è TurboSETI [4, 5], un programma sviluppato all’interno di Breakthrough Listen per identificare segnali a banda stretta che derivano in frequenza nel tempo. TurboSETI, infatti, cerca esplicitamente uno specifico tipo di pattern — una linea inclinata nel diagramma tempo–frequenza, prodotta da un segnale a frequenza costante osservato da uno strumento in moto relativo rispetto alla sorgente — e per questo è altamente specializzato. Il limite principale è proprio questa specializzazione: il programma è ottimizzato per un comportamento atteso del segnale e perde i candidati che si discostano da esso, in particolare quelli con derive di frequenza molto elevate o con morfologie non lineari.

Una seconda famiglia di approcci utilizza tecniche di apprendimento automatico supervisionato addestrate su segnali iniettati artificialmente in dati reali. Il lavoro di Brzycki et al. [6] ne è un esempio rappresentativo: una rete neurale convoluzionale apprende a

¹Codice disponibile su GitHub: <https://github.com/DavideDeplano/srt-anomaly-detection>

localizzare segnali a banda stretta sintetici inseriti in osservazioni di rumore reale, ottenendo prestazioni superiori a quelle dei metodi classici nei regimi a basso rapporto segnale-rumore. Il limite di questo paradigma è che il modello apprende le caratteristiche dei segnali simulati, e generalizza correttamente solo nella misura in cui i segnali sintetici riproducono fedelmente quelli che si vorrebbero rilevare; assunzione difficile da verificare in un contesto in cui il segnale di interesse non è noto.

Una terza famiglia di approcci, più recente, sposta l'attenzione dal riconoscimento del segnale al riconoscimento dell'anomalia: invece di addestrare il modello a riconoscere ciò che si cerca, lo si addestra a riconoscere ciò che è ordinario nei dati osservativi, in modo da segnalare come potenziali candidati le osservazioni che si discostano da tale comportamento. Il lavoro di Ma et al. [7] utilizza un autoencoder semi-supervisionato per identificare candidati anomali in un campione di osservazioni di stelle vicine, mentre Jacobson-Bell et al. [8] applicano tecniche di clustering ai segnali identificati da TurboSETI per individuare outlier morfologici all'interno dell'insieme degli RFI già rilevati. Entrambi gli approcci hanno il vantaggio di non richiedere ipotesi forti sulla forma del segnale ricercato, ma differiscono per il tipo di anomalia che riescono a catturare e per il livello a cui operano nella pipeline di analisi.

In questo panorama il lavoro di Pardo et al. (2025) [1] occupa una posizione specifica: è un approccio di anomaly detection non supervisionato, in cui i modelli statistici a monte (UMAP, KDE, GMM) non vengono addestrati a riconoscere il segnale di interesse ma a caratterizzare la distribuzione tipica delle osservazioni, e i candidati anomali vengono selezionati per scarto dalla distribuzione attesa. Rispetto agli altri lavori della stessa famiglia, la pipeline ha tre caratteristiche distintive che ne motivano l'adozione come riferimento. Innanzitutto, è stata applicata end-to-end al volume completo di dati di Breakthrough Listen, validandone l'utilizzabilità su scala reale; in secondo luogo, la sua struttura modulare a stadi indipendenti — descritta nel dettaglio nel Capitolo 2 — ne facilita il porting in un contesto osservativo differente; in terzo luogo, le scelte metodologiche degli autori sono completamente documentate nel testo del lavoro, condizione necessaria per la riproduzione fedele della pipeline in assenza di codice ereditato. Per queste ragioni essa è stata adottata come base metodologica del presente lavoro, e i capitoli successivi

ne discutono in dettaglio sia la riproduzione che le modifiche introdotte per adattarla ai dati del Sardinia Radio Telescope.

Vediamo ora da dove la pipeline di Pardo et al. parte e quali questioni lascia aperte. Il punto di partenza è un volume estremamente ampio di osservazioni del Green Bank Telescope nelle bande L, S e 10 cm, su cui gli autori applicano una catena di tre filtri statistici e ottengono come risultato una riduzione di sette ordini di grandezza dello spazio di ricerca, lasciando un sottoinsieme di candidati di dimensioni gestibili per l'ispezione manuale. Gli autori stessi, nelle loro conclusioni, identificano due limiti principali del lavoro che lasciano aperti a sviluppi futuri: l'analisi è condotta a una scala fissa nel piano tempo-frequenza, mentre un sistema multi-scala consentirebbe di catturare segnali con caratteristiche più eterogenee, e il processo di vetting manuale dei candidati promossi rimane oneroso, suggerendo l'opportunità di tecniche aggiuntive di filtraggio a valle. Il presente lavoro non affronta direttamente questi due problemi, ma si muove in una direzione complementare: verificare se la pipeline, calibrata su un singolo strumento, sia trasferibile a un contesto osservativo differente, come il SRT — questione non discussa nel lavoro originale — e valutare l'introduzione di un filtro alternativo basato su autoencoder che opera direttamente nello spazio delle feature, come prima ipotesi di superamento della dipendenza della pipeline dalla qualità dell'embedding bidimensionale prodotto da UMAP.

1.5 UMAP Reverse Search

Durante lo sviluppo della pipeline è stato realizzato uno strumento di esplorazione interattiva, denominato UMAP Reverse Search, originariamente concepito come supporto al lavoro implementativo e mantenuto poi come componente del sistema finale. La motivazione che ne ha determinato la nascita merita di essere riportata, perché illustra una difficoltà tipica del lavoro su pipeline di anomaly detection in cui i dati di interesse non sono noti a priori.

Nel corso dell'adattamento della pipeline ai dati del Sardinia Radio Telescope si è presentata una situazione di stallo: i modelli statistici a monte producevano risultati

numericamente plausibili, ma non vi era un modo immediato per verificare se i candidati promossi corrispondessero effettivamente alla regione attesa dello spazio latente costruito dai modelli. In altre parole, era possibile osservare *quali* candidati superavano i vari stadi di selezione, ma non *dove* si collocavano rispetto alla struttura del modello. UMAP Reverse Search nasce per rispondere a questa esigenza pratica.

Lo strumento riutilizza il modello UMAP [9] addestrato sui dati simulati e proietta nello stesso spazio bidimensionale i candidati reali del SRT, senza richiedere alcun riaddestramento. Il risultato è una visualizzazione interattiva che sovrappone due livelli informativi: sullo sfondo i dati simulati di addestramento, colorati in base alla categoria di appartenenza, e in primo piano i candidati reali, colorati in base alla banda osservativa (banda C e banda K). Selezionando un candidato è possibile consultarne i metadati associati e individuarne immediatamente la posizione rispetto alle regioni di interesse; in aggiunta, una funzionalità di ricerca per prossimità permette di recuperare automaticamente i candidati reali più vicini a uno selezionato entro un raggio configurabile, facilitando l'identificazione di osservazioni morfologicamente simili.

La Figura 1.3 mostra la distribuzione globale dei candidati reali nello spazio del modello, sovrapposta ai cluster del training set simulato. La Figura 1.4 riporta la vista interattiva ottenuta selezionando un candidato promosso, con il pannello dei metadati visualizzato a lato.




Figura 1.3: UMAP Reverse Search: distribuzione globale dei candidati reali (banda C in ciano, banda K in viola) proiettati nello spazio bidimensionale del modello statistico, sovrapposti al training set simulato colorato per categoria. La massa centrale corrisponde ai candidati con struttura compatibile con il rumore di fondo, mentre la regione di interesse simulata (in verde) è collocata sul margine sinistro dell'embedding.



Figura 1.4: Vista interattiva dello strumento: selezionando un candidato promosso, il pannello laterale ne riporta i metadati (identificativo, banda, frequenza, coordinate nello spazio del modello) e il percorso del file sorgente. Il candidato selezionato si colloca in corrispondenza della regione di interesse simulata (in verde), distinta dalla nube principale dei candidati.

Pur essendo nato come strumento di supporto allo sviluppo, UMAP Reverse Search ha trovato anche un ruolo di utilità operativa: la possibilità di esplorare visivamente la collocazione dei candidati rispetto alle regioni del modello consente di affiancare la selezione automatica con un’ispezione qualitativa più efficiente, fornendo un mezzo di interpretazione complementare al filtraggio numerico discusso nel Capitolo 2.

Capitolo 2

Anomaly detection applicato al SETI

In questo capitolo viene presentata la pipeline di anomaly detection proposta da Pardo et al. (2025) [1] come riferimento metodologico del lavoro e ne viene descritto l'adattamento, modulo per modulo, ai dati del Sardinia Radio Telescope. La pipeline è stata implementata interamente a partire dal paper di riferimento, senza alcun codice ereditato dagli autori: ogni modulo è stato ricostruito secondo l'architettura descritta nel lavoro originale, e le scelte operative per il SRT sono state introdotte direttamente all'interno dell'implementazione. Per ciascuno dei tre filtri che compongono la pipeline — Density Filter, Frequency Filter e Similarity Filter — la trattazione segue lo stesso schema: si inizia con la descrizione del modulo come proposto nel lavoro originale, e immediatamente dopo si prosegue con le modifiche architetturali introdotte in questo lavoro per renderlo applicabile al contesto osservativo del SRT.

L'esposizione integrata mette in luce, nel punto in cui ciascuna scelta viene presentata, tre criticità del lavoro originale che hanno motivato le modifiche architetturali introdotte. La prima riguarda l'estrattore di feature: il termine *cross-correlation* usato dagli autori indica, in elaborazione dei segnali, una misura calcolata su un insieme di spostamenti relativi, mentre l'implementazione di riferimento calcola la correlazione di Pearson a spostamento nullo, ovvero il solo caso a lag zero; la conseguenza è che il filtro originale non riconosce i segnali a deriva di frequenza, comportamento atteso da una sorgente celeste reale. La seconda riguarda il *Density Filter*: la soglia di promozione è un valore fisso calibrato sulla distribuzione delle probabilità osservata sui dati del Green Bank Telesco-

pe, e non è trasferibile a un contesto osservativo con caratteristiche statistiche differenti. La terza riguarda il *Similarity Filter*: il preprocessing standard adottato dagli altri stadi della pipeline include una correzione della risposta in banda che sopprime le componenti spettrali persistenti nel tempo, ovvero proprio la morfologia che il filtro deve riconoscere.

Il capitolo è organizzato come segue. La Sezione 2.1 descrive l’architettura generale della pipeline a livello concettuale, secondo la formulazione di Pardo et al. (2025); la Sezione 2.2 presenta l’architettura del sistema implementato, con le interfacce e le classi che ne realizzano la struttura modulare. La Sezione 2.3 discute i dati su cui il sistema opera, simulati e reali, e le differenze sul piano dei dati tra il setting originale e quello del SRT. La Sezione 2.4 introduce l’estrattore di feature di cross-correlazione, ne presenta la variante NCC-max e ne valida sperimentalmente le proprietà tramite un test di iniezione controllata (Sezione 2.4.3). Le Sezioni 2.5, 2.6 e 2.7 sono dedicate, ciascuna, a uno dei tre filtri, esposti secondo lo schema descritto sopra. La Sezione 2.8 chiude il capitolo presentando il modulo di ranking che combina i punteggi prodotti dai tre filtri.

2.1 Architettura generale della pipeline

La pipeline proposta da Pardo et al. (2025) [1] è un sistema multi-stadio per la riduzione automatica dello spazio di ricerca SETI. L’obiettivo non è classificare i candidati come segnali extraterrestri, ma eliminare in modo sistematico quelli che presentano caratteristiche compatibili con il rumore di fondo o con l’interferenza radio terrestre, lasciando al ricercatore un sottoinsieme ristretto di candidati ad alta priorità, da ispezionare manualmente.

Il sistema riceve in ingresso un insieme di cadenze ON/OFF estratte dalle osservazioni radioastronomiche e le processa attraverso tre filtri indipendenti applicati in sequenza. Il primo è il *Density Filter*, basato su Uniform Manifold Approximation and Projection (UMAP) e Kernel Density Estimation (KDE), che opera sulle feature di cross-correlazione tra i pannelli della cadenza e scarta i candidati la cui distribuzione statistica è compatibile con quella del rumore simulato. Il secondo è il Frequency Filter, basato su un ensemble di Gaussian Mixture Models (GMM), che assegna a ciascun candidato un punteggio di ano-

malia in base alla rarità della sua frequenza centrale rispetto alla distribuzione osservata. Il terzo è il Similarity Filter, che valuta la coerenza spaziale del segnale tra i pannelli ON e OFF tramite una metrica di distanza in uno spazio UMAP bidimensionale.

I tre punteggi prodotti dai filtri vengono infine combinati da un modulo di Ranking, che seleziona i candidati con i punteggi più elevati per la revisione manuale. L'architettura è progettata per essere modulare e indipendente: ciascun filtro opera autonomamente e può essere addestrato, aggiornato o sostituito senza modificare gli altri componenti del sistema. Lo schema complessivo della pipeline è illustrato in Figura 2.1.




Figura 2.1: Schema a blocchi della pipeline di Pardo et al. (2025) [1]. Le cadenze ON/OFF in ingresso vengono filtrate dal Density Filter, che opera come cancello binario: i candidati promossi vengono poi valutati in parallelo dal Frequency Filter e dal Similarity Filter, ciascuno dei quali assegna un punteggio continuo. I due punteggi confluiscono nel modulo di Ranking, che li combina per costruire i quattro campioni di output destinati alla revisione manuale.

2.2 Architettura del sistema implementato

L’implementazione della pipeline è stata realizzata interamente a partire dal paper di riferimento [1], senza alcun codice ereditato dagli autori, ed è pubblicamente disponibile sul repository `srt-anomaly-detection`. Il sistema è scritto in Python e si appoggia alle librerie standard dell’ecosistema scientifico per le componenti numeriche e di apprendimento automatico — in particolare `numpy` e `scipy` per il calcolo numerico, `scikit-learn` [10] per UMAP, KDE e GMM, `tensorflow/keras` [11] per la rete neurale impiegata nello stadio descritto nel Capitolo 3, e `blimpy` [12] per la lettura dei file nativi del backend di acquisizione del SRT.

La definizione dei moduli del sistema rispecchia la struttura della pipeline descritta nella Sezione 2.1: a ciascuno dei tre filtri logici corrisponde una classe del codice, e gli altri compiti — caricamento dei dati, generazione delle cadenze sintetiche, ranking e visualizzazione — sono incapsulati in classi distinte. Questa scelta progettuale è stata necessaria perché il paper di riferimento descrive l’architettura della pipeline ma non ne fornisce un’implementazione completa: in assenza di codice ereditato, ciascun modulo è stato ricostruito sulla base della descrizione testuale degli autori, riproducendone fedelmente le componenti per le quali la descrizione è sufficientemente dettagliata — estrazione delle feature, generazione del dataset sintetico, costruzione dei modelli KDE e GMM, calcolo dei punteggi — e introducendo assunzioni esplicite dove la descrizione lascia margini di interpretazione. La sostituzione della correlazione di Pearson a lag zero con l’estrattore NCC-max (Sezione 2.4.2) costituisce l’unica componente sviluppata *ex novo* rispetto al modello del paper: si tratta di una variante della feature originale, non di un modulo aggiuntivo, motivata dall’ambiguità terminologica anticipata nel cappello del capitolo. Una validazione diretta dell’implementazione del sistema proposto da Pardo et al. [1] non è stata possibile, poiché non è disponibile né il dataset sintetico né l’insieme di candidati reali del Green Bank Telescope su cui gli autori hanno calibrato i loro modelli: la verifica delle scelte operative è stata quindi condotta in modo indipendente, tramite test di iniezione controllata (Sezione 2.4.3) e tramite l’analisi statistica dei risultati sui dati del SRT. L’adattamento al SRT ha richiesto anche la ridefinizione della configurazione operativa

— bande osservative, numero di componenti dei modelli, ampiezza dei segnali sintetici, soglia di promozione del Density Filter — discussa nelle sezioni dedicate ai singoli filtri.

Il contratto comune tra gli stadi di scoring è definito dall’interfaccia astratta **IFilter**, che impone a ogni filtro l’esposizione di un metodo `fit` per l’addestramento, di un metodo `calculate` per il calcolo del punteggio di un singolo candidato e di due metodi protetti per la persistenza dei modelli su disco. L’interfaccia è realizzata dai quattro filtri presenti nel sistema — Density, Frequency, Similarity e Autoencoder — che vengono orchestrati dal modulo principale come una sequenza uniforme. L’addestramento di ciascun filtro è idempotente: se i modelli associati esistono già su disco vengono caricati direttamente, altrimenti vengono addestrati e salvati al termine. Questa proprietà permette di rieseguire gli stadi successivi della pipeline senza ricalibrare quelli già completati, riducendo in modo significativo il tempo di iterazione durante lo sviluppo.

Il flusso dei dati è organizzato attorno alla classe **Candidate**, che incapsula il tensore della cadenza nelle sue due rappresentazioni — preprocessata e *cadence_raw* (Sezione 2.7) — i metadati osservativi e gli score prodotti da ciascun filtro. Ogni stadio della pipeline arricchisce l’oggetto con il proprio risultato attraverso un *setter* dedicato, e il modulo di ranking opera infine sulla collezione completa per costruire i campioni finali. Due classi ausiliarie sostengono i filtri più complessi: **CrossCorrelationExtractor** produce il vettore di feature a 15 componenti del Density Filter, disaccoppiato dal filtro stesso per consentire la sostituzione della correlazione di Pearson a lag zero con l’estrattore NCC-max (Sezione 2.4.2) senza modifiche al filtro, mentre **AEHyperModel** incapsula lo spazio di ricerca dell’autoencoder per il tuner di Keras (Capitolo 3). Il diagramma UML delle classi del sistema è riportato in Figura 2.2.




Figura 2.2: Diagramma UML delle classi del sistema. Le quattro classi di filtro implementano l'interfaccia `IFilter`; `Candidate` è l'oggetto attraverso cui transitano dati e punteggi tra gli stadi; `Ranker` e `Visualizer` operano sulla collezione finale dei candidati.

Il flusso di esecuzione del sistema è illustrato nel diagramma di sequenza in Figura 2.3. Una sessione di analisi inizia con il caricamento delle cadenze reali da parte del `Dataset`, che produce gli oggetti `Candidate` con entrambe le rappresentazioni del segnale; segue l'applicazione in cascata dei tre filtri di scoring, ciascuno dei quali aggiorna lo score corrispondente sul candidato; il `Ranker` opera infine sulla collezione completa per produrre le quattro selezioni finali (per percentile di frequenza, per percentile di similarità, Top-K combinato e controllo casuale), che il `Visualizer` restituisce sotto forma di figure di sintesi. La generazione del dataset sintetico tramite `SimulationGenerator` e l'addestramento dei modelli avvengono una sola volta a monte, in modalità riprendibile come descritto sopra.




Figura 2.3: Diagramma UML di sequenza della pipeline. Dopo il caricamento dei candidati, i tre filtri di scoring vengono applicati in cascata e i risultati sono aggregati dal modulo di ranking.

2.3 Dati

I dati su cui opera il sistema appartengono a due categorie distinte: cadenze sintetiche generate per l'addestramento dei modelli, e cadenze reali acquisite con il Sardinia Radio Telescope sulle quali i modelli vengono applicati in fase di inferenza. Le due famiglie di dati sono descritte nelle Sezioni 2.3.1 e 2.3.2; la Sezione 2.3.3 discute le differenze tra il setting originale di Pardo et al. (2025) e quello del SRT, e le scelte operative adottate per colmarle.

2.3.1 Dati simulati

Un elemento centrale della pipeline è l'utilizzo di cadenze sintetiche per addestrare i modelli di filtraggio. Poiché i segnali di origine extraterrestre sono per definizione sconosciuti, non è possibile disporre di esempi positivi reali per l'addestramento. La soluzione adottata da Pardo et al. (2025) [1] è generare un grande numero di cadenze simulate che coprono sistematicamente tutte le possibili combinazioni di pattern ON/OFF, in modo da approssimare la distribuzione statistica attesa di un segnale artificiale.

Ogni cadenza è composta da sei pannelli, corrispondenti alle sei osservazioni alternate ON/OFF di una singola sessione, con dimensione 16×80 pixel per pannello (16 elementi temporali, 80 elementi frequenziali corrispondenti a una finestra di circa 220 Hz). Per ciascuna cadenza vengono generate tutte le combinazioni binarie possibili dei sei slot ($2^6 = 64$), ottenendo un insieme di addestramento che copre uniformemente lo spazio dei pattern. Un aspetto metodologico centrale, ereditato direttamente da Pardo et al., è che le cadenze simulate non costituiscono, e non devono costituire, una riproduzione morfologicamente fedele dei waterfall reali del SRT: il formato compatto di ciascun pannello e l'assenza di artefatti strumentali, sub-strutture e componenti a banda larga sono scelte deliberate, non un limite dell'approccio. Come illustrato in Figura 2.4, ogni cadenza è una rappresentazione schematica in cui l'unico elemento distintivo del segnale è una sottile linea narrowband inserita nei soli pannelli marcati ON, quale marcatore geometrico – e non morfologico – della presenza del segnale nella cadenza. L'obiettivo della simulazione non è dunque imitare l'aspetto dei waterfall osservati, ma coprire in modo esaustivo le 64 categorie di pattern ON/OFF nello spazio delle feature: proiettando queste cadenze nello spazio ridotto ottenuto tramite UMAP (Sezione 3.1), ciascuna categoria occupa una regione ben definita, e sono queste regioni – non la forma del segnale – a costituire il criterio decisionale dei filtri. Questa astrazione è essenziale per la filosofia *unsupervised* dell'anomaly detection: le 64 categorie che i filtri devono apprendere sono definite esclusivamente dalla posizione del segnale nei sei slot (lo schema ON/OFF), non dalla sua forma dettagliata. Introdurre nelle cadenze simulate una morfologia realistica del segnale significherebbe imporre *a priori* un modello di come il segnale extraterrestre dovrebbe apparire,

contraddicendo l'ipotesi fondamentale che la sua forma sia ignota; il compito dei filtri è invece identificare candidati compatibili con il pattern only-on, indipendentemente dalla loro morfologia specifica.

In ciascun pannello marcato come ON è inserito un segnale narrowband sintetico con parametri campionati casualmente: frequenza di partenza, drift rate (tasso di deriva in frequenza), ampiezza relativa al rumore locale e profilo spettrale e temporale. I segnali sintetici vengono generati con la libreria `setigen` [13], che permette di inserire segnali narrowband con deriva di frequenza lineare all'interno di frame radioastronomici realistici. L'ampiezza del segnale è definita come fattore moltiplicativo rispetto al massimo locale del rumore di fondo, garantendo una variabilità realistica del rapporto segnale-rumore (SNR) nelle cadenze simulate. Il rumore di fondo è estratto da dati reali del telescopio, in modo da preservare le caratteristiche statistiche del contesto osservativo.




Figura 2.4: Esempio di cadenza simulata generata dalla pipeline, appartenente al pattern 42 (ON-OFF-ON-OFF-ON-OFF). Il segnale narrowband, visibile come sottile linea drifting nei tre pannelli ON, è iniettato su rumore reale del SRT.

2.3.2 Dati reali del SRT

I dati utilizzati in questo lavoro provengono da osservazioni condotte con il Sardinia Radio Telescope nelle bande C (4.2–7.7 GHz) e K (18–26.5 GHz). Ogni sessione osservativa segue il pattern ON/OFF tipico delle ricerche SETI: il telescopio punta alternativamente verso la stella bersaglio (osservazione ON) e verso una posizione di riferimento vicina (osservazione OFF), producendo una cadenza di sei osservazioni nella sequenza ON/OFF/ON/OFF/ON/OFF. Un segnale presente solo nelle tre osservazioni ON è compatibile con una sorgente nella direzione del bersaglio; un segnale presente anche nelle OFF è con ogni probabilità interferenza radio (RFI) locale.

I dati grezzi sono archiviati in formato `.h5`, il formato nativo del backend di acquisizione del SRT. Per renderli compatibili con la pipeline è stato implementato lo script `h5_to_candidates.py`, che scandisce ricorsivamente una directory di file `.h5`, letti tramite la libreria `blimpy` [12], raggruppa i file in cadenze valide sulla base del nome del bersaglio, della data di osservazione e del pattern ON/OFF, e scarta automaticamente le cadenze incomplete o con pattern non conforme. Ogni cadenza valida viene poi percorsa lungo l'asse della frequenza con una finestra di 4096 canali grezzi (circa 11.4 kHz), e ogni finestra viene salvata come immagine PNG. L'output è bilanciato tra banda C e banda K tramite *interleaving*, in modo che nessuna delle due bande sovrarappresenti l'altra nell'insieme dei candidati.

Ogni PNG rappresenta la cadenza come una colonna di sei pannelli, uno per osservazione, alla risoluzione di canale originale. Ogni pannello viene trasformato in scala logaritmica e normalizzato tra 0 e 1 sul proprio minimo e massimo; quando l'asse delle frequenze del file decresce, la finestra viene specchiata in modo che la frequenza cresca sempre da sinistra a destra. L'etichetta di frequenza dell'immagine è quella del canale centrale della finestra, e il nome del file include un identificativo univoco della cadenza, che permette di distinguere cadenze diverse dello stesso bersaglio e di risalire sempre dall'immagine ai dati di origine.

In fase di caricamento, i PNG vengono ritagliati, suddivisi nei sei pannelli e riportati alla dimensione dei frame sintetici (16 campioni temporali per 80 colonne di frequenza).

A ciascun pannello viene applicato lo stesso preprocessing usato per le cadenze simulate: normalizzazione di ogni riga per la propria media temporale, rimozione del picco a frequenza zero (*direct current*, DC) per interpolazione con i canali adiacenti, e correzione della risposta in banda tramite regressione con B-spline (curva polinomiale a tratti definita su un insieme di nodi). Questa simmetria garantisce che i candidati reali e quelli simulati siano rappresentati nello stesso spazio di feature, condizione necessaria affinché i modelli addestrati sul dataset sintetico possano essere applicati ai dati osservativi senza introdurre bias sistematici.

Il dataset finale ottenuto al termine del processo di conversione e caricamento è composto da 180.242 finestre PNG, bilanciate tra banda C e banda K tramite interleaving in fase di estrazione, e costituisce l'insieme dei candidati reali su cui sono stati applicati tutti gli stadi della pipeline.

2.3.3 Differenze rispetto al setting originale

L'applicazione della pipeline ai dati del SRT comporta tre differenze rispetto al setting originale di Pardo et al. (2025), che riguardano la composizione del dataset di addestramento e non l'architettura dei filtri. La prima riguarda le bande osservative: la pipeline originale opera sulle bande L, S e 10 cm del Green Bank Telescope (GBT) e del Parkes Telescope, coprendo l'intervallo 1.10–3.45 GHz; nel presente lavoro le bande operative sono la banda C (4.2–7.7 GHz) e la banda K (18–26.5 GHz) del SRT, di conseguenza il dataset sintetico è stato generato sulle due bande del SRT, e tutti i modelli che operano separatamente per banda — Frequency Filter in particolare — sono stati addestrati di conseguenza.

La seconda riguarda il rumore di fondo utilizzato per generare le cadenze simulate. Nel lavoro originale il rumore è estratto da una singola cadenza in banda S della stella HIP 17147; in questa implementazione il background è costruito a partire da file `.h5` provenienti da più sessioni osservative del SRT in giorni distinti, in modo da campionare la variabilità reale del rumore strumentale nel tempo e rendere il dataset simulato più rappresentativo delle condizioni operative effettive.

La terza riguarda l'ampiezza dei segnali sintetici. Nel generatore il fattore di ampiezza α agisce come moltiplicatore diretto del picco del rumore del pannello, con livello del segnale iniettato definito come $L = \alpha \cdot \max(N)$, dove N è la realizzazione di rumore di fondo copiata negli slot della cadenza. Il range originale $[0.0, 4.0]$ adottato in [1] è tarato sulla cadenza S-band (1.80–2.80 GHz) del target HIP 17147 acquisita al Green Bank Telescope, mentre la presente pipeline utilizza un background estratto da osservazioni reali del Sardinia Radio Telescope nelle bande C (4.2–7.7 GHz) e K (18–26.5 GHz): bande, ricevitori, temperature di sistema e ambiente RFI differiscono in modo sostanziale [14], e il significato operativo di α ne risente. In questo contesto, il sotto-range $\alpha < 1$ produce per costruzione cadenze in cui il segnale iniettato resta al di sotto del picco del rumore locale SRT e non è distinguibile dal rumore stesso, pur essendo etichettato come segnale presente: un caso di rumore di etichetta (*label noise*) che rischia di indurre il modello ad associare l'etichetta di segnale a strutture del solo rumore di fondo. Su questa base, e a seguito di un confronto con il gruppo di ricerca del Berkeley SETI Research Center, il range è stato riformulato come $[4.0, 10.0]$, garantendo per costruzione $\alpha \geq 4$ tra picco del segnale e picco del rumore locale. La scelta introduce una limitazione esplicita del dominio di validità: il modello è addestrato sul regime dei segnali chiaramente separabili dal rumore SRT, mentre i segnali reali con ampiezza prossima al picco di rumore ($\alpha < 4$) escono dalla distribuzione appresa e non sono garantiti come rilevabili dai filtri della pipeline.

2.4 Estrattore di feature di cross-correlazione

2.4.1 L'estrattore di Pardo e il suo limite strutturale

Nella pipeline di riferimento, ogni cadenza viene descritta da un vettore di 15 valori, uno per ciascuna coppia possibile dei 6 pannelli. Il lavoro originale [1] descrive queste quantità come feature di *cross-correlazione*, termine che in elaborazione dei segnali indica una misura calcolata su un insieme di spostamenti relativi tra i due segnali. L'implementazione di riferimento, tuttavia, calcola la correlazione di Pearson a spostamento nullo, che della

cross-correlazione è soltanto il caso particolare a lag zero. Questa ambiguità terminologica è rilevante, perché le due letture hanno proprietà molto diverse. L’idea di fondo del filtro resta comunque semplice: se un segnale compare nella stessa posizione in tutti i pannelli ON e in nessun pannello OFF, le coppie ON–ON avranno correlazione alta e le coppie miste correlazione bassa, e questo schema identifica la categoria di interesse.

La correlazione a spostamento nullo ha, però, un limite strutturale: confronta i pannelli pixel per pixel, nella stessa posizione. Se il segnale si sposta in frequenza tra un’osservazione e l’altra — come ci si aspetta da una sorgente celeste reale, per effetto del moto relativo tra trasmettitore e ricevitore [1] — nei pannelli ON il segnale non si trova più alla stessa posizione, la correlazione crolla e il candidato diventa invisibile al filtro, indipendentemente da quanto sia intenso.

2.4.2 Definizione di NCC-max

Per superare questo limite è stata introdotta una variante dell’estrattore, denominata NCC-max, che invece di calcolare la correlazione a posizione fissa, per ogni coppia di pannelli si calcola la cross-correlazione normalizzata (Normalized Cross-Correlation, NCC) su un insieme di spostamenti relativi (*lag*) e si prende il valore massimo. Gli spostamenti ammessi sono limitati a una finestra pari al 10% dell’asse di frequenza (cioè ± 8 colonne su 80), mentre in tempo si mantiene il solo lag zero: la finestra è coerente con il comportamento atteso del segnale tra pannelli, che deriva in frequenza per effetto Doppler ma non introduce traslazioni temporali significative all’interno del singolo pannello. La feature diventa così tollerante alle piccole traslazioni in frequenza tra pannelli, senza premiare allineamenti casuali a distanze arbitrarie. Quando lo spostamento è nullo, la cross-correlazione normalizzata coincide esattamente con la correlazione di Pearson: la variante NCC-max è quindi una generalizzazione della feature originale, non una misura diversa.

Il vettore di feature mantiene la stessa dimensione (15 valori per cadenza) e il resto della pipeline — proiezione UMAP, modelli KDE, classificazione per categoria — resta invariato. L’implementazione dell’estrattore NCC-max è disponibile nel modulo

`CrossCorrelationExtractor` del repository. Le conseguenze pratiche di questa scelta sono verificate sperimentalmente nella Sezione 2.4.3.

2.4.3 Validazione: test di iniezione controllata

In assenza di segnali tecnologici noti nei dati SRT, la sensibilità dell’estrattore è stata verificata con un test di iniezione controllata (*positive control*), il cui scopo è verificare che l’estrattore rilevi correttamente un segnale iniettato di forma nota, non caratterizzarne statisticamente la sensibilità: per questo obiettivo una singola cadenza pulita è sufficiente. La cadenza utilizzata (TIC 371234684, banda C) è stata selezionata tramite uno script che, per ogni finestra candidata, calcola la deviazione standard dell’intensità nei pannelli OFF e restituisce la finestra con il valore minimo: una regione priva di picchi di RFI e di righe narrowband preesistenti, in cui il segnale di fondo è dominato dal solo rumore termico del ricevitore. Questa scelta garantisce che il segnale iniettato non sia contaminato da strutture spettrali già presenti nella cadenza e che l’SNR nominale corrisponda effettivamente al rapporto tra il picco del segnale iniettato e la deviazione standard del rumore locale. Nella regione selezionata è stato iniettato un segnale a banda stretta (2 canali) esclusivamente nelle tre osservazioni ON, a sei livelli di ampiezza espressi in unità della deviazione standard locale del rumore (SNR 5, 10, 20, 50, 100, 200). Sono state testate due larghezze di finestra: 4096 canali, la finestra di produzione, e 640 canali, prossima alla scala dei frame sintetici di addestramento. I PNG risultanti sono stati generati con la pipeline di rendering di produzione e classificati dal Density Filter senza alcuna modifica.

Il test è stato condotto in due varianti. Nella variante a *posizione fissa* il segnale riparte alla stessa frequenza in ogni pannello ON, replicando la convenzione del generatore sintetico, che non modella l’intervallo temporale tra osservazioni successive. Nella variante *drifting* il segnale deriva coerentemente lungo l’intera linea temporale della cadenza, come farebbe un segnale celeste reale, con un tasso di 0,5 Hz/s, valore interno all’intervallo dei parametri del generatore sintetico (± 4 Hz/s, ripreso da [1]). Gli stessi PNG sono stati classificati sia dal modello basato sulla correlazione di Pearson a lag zero sia dalla variante NCC-max; come controllo aggiuntivo, entrambi i modelli sono stati applicati a un insieme di 18 finestre candidate reali ($9 \text{ sorgenti} \times 2 \text{ frequenze}$). La Tabella 2.1 riassume i risultati

come numero di candidati con *argmax* nella categoria only-ON (Cat 42), ovvero candidati per i quali il modello assegna la probabilità più alta al pattern con segnale nei soli pannelli ON. Un esempio di cadenza iniettata è mostrato in Figura 2.5.

Modello	Iniezione fissa	Iniezione drifting (0,5 Hz/s)	Candidati reali
Pearson	12/12	0/12	1/18
NCC-max	11/12	3/12	1/18

Tabella 2.1: Test di iniezione e controllo su candidati reali: numero di candidati assegnati alla categoria only-ON (Cat 42). Le iniezioni comprendono 12 PNG per variante (2 finestre $\times$ 6 livelli di SNR) sulla medesima cadenza reale.

Nella variante a posizione fissa entrambi i modelli rilevano correttamente le iniezioni: il modello Pearson assegna Cat 42 a tutti i 12 casi, la variante NCC-max a 11 su 12, con un unico mancato rilevamento nel caso più debole (SNR 5 sulla finestra da 4096 canali). La sensibilità empirica a posizione fissa risulta quindi $\text{SNR} \geq 5$ sulla finestra da 640 canali e $\text{SNR} \geq 10$ su quella da 4096 canali.




Figura 2.5: Esempio di cadenza con iniezione drifting (finestra da 4096 canali, SNR 200): il segnale a banda stretta è presente solo nelle tre osservazioni ON, in posizione leggermente diversa in ciascun pannello per effetto della deriva in frequenza, ed è assente nelle osservazioni OFF.

I risultati della variante drifting riflettono direttamente le proprietà di invarianza delle due feature. La correlazione a lag zero richiede la sovrapposizione posizionale del segnale tra i pannelli ON: a $0,5 \text{ Hz/s}$ lo spostamento tra osservazioni ON consecutive ($\approx 319 \text{ Hz}$, pari a diverse colonne della griglia di caricamento) annulla la correlazione, e il modello Pearson non assegna la categoria only-ON ad alcun livello di ampiezza. La feature NCC-max, che ricerca il massimo della cross-correlazione normalizzata entro una finestra di ± 8 colonne, recupera il rilevamento sulla finestra di produzione a partire da SNR 50; sulla finestra da 640 canali la scala in Hz per colonna è più fine, lo stesso drift eccede la finestra di lag e il segnale non viene rilevato. La tolleranza al drift dipende quindi dalla larghezza

della finestra: circa 0,9 Hz/s a 4096 canali e circa 0,3 Hz/s a 640 canali.

Sui 18 candidati reali i due modelli mostrano la stessa selettività (1/18) ma promuovono finestre diverse: il modello Pearson seleziona TIC 121966220 a 4859,98 MHz, la variante NCC-max seleziona TIC 371234684 alla stessa frequenza. La divergenza è coerente con il fatto che le due feature misurano strutture differenti (sovrapposizione posizionale contro allineamento tollerante alla traslazione); in entrambi i casi la revisione umana resta il passo conclusivo prima di qualunque conclusione sull'autenticità dei segnali. Si osserva infine che il test costituisce una verifica controllata su una singola cadenza e un singolo tasso di drift, non una caratterizzazione statistica della sensibilità.

Alla luce di questi risultati, la variante NCC-max è stata adottata come modello finale: a fronte di una soglia di ampiezza più elevata nel caso drifting, è l'unica delle due a rilevare segnali che derivano in frequenza tra osservazioni successive, ovvero il comportamento atteso da una sorgente celeste reale.

2.5 Density Filter

2.5.1 Descrizione del filtro nel lavoro di Pardo et al.

Il Density Filter è il primo stadio della pipeline e ha il ruolo di scartare i candidati la cui struttura statistica è compatibile con quella del rumore di fondo simulato. Il filtro opera sulle feature di cross-correlazione estratte dai sei pannelli di ciascuna cadenza (Sezione 2.4): da ogni coppia di pannelli viene ricavata una misura di correlazione, producendo un vettore di 15 valori che rappresenta la struttura di correlazione interna della cadenza.

Questi vettori vengono proiettati in uno spazio bidimensionale tramite UMAP [9], tecnica di riduzione dimensionale non lineare che preserva la struttura locale e globale dei dati. La proiezione UMAP viene addestrata sull'insieme delle cadenze simulate, che coprono tutte le 64 combinazioni di pattern ON/OFF. Nel piano bidimensionale risultante, le cadenze si organizzano in regioni distinte in base al loro pattern: le cadenze con segnale solo nei pannelli ON si separano naturalmente da quelle con segnale distribuito uniformemente o assente.

Per ciascuna delle 64 categorie simulate viene addestrato un modello KDE [10] nello spazio UMAP, che stima la distribuzione di probabilità della categoria corrispondente. Durante l’inferenza, un candidato reale viene proiettato nello stesso spazio UMAP e valutato da tutti i modelli KDE: il candidato supera il filtro solo se la categoria con probabilità più alta è quella *only-on-target* (segnale presente esclusivamente nei pannelli ON) e se tale probabilità supera la soglia, fissata a 0.0618 nel lavoro originale. I candidati che superano il filtro vengono passati agli stadi successivi della pipeline per una valutazione ulteriore; tutti gli altri vengono scartati.

2.5.2 Soglia adattiva

Nel lavoro originale la soglia (0.0618) è un valore fisso, determinato empiricamente osservando la distribuzione delle probabilità su un campione di stelle reali osservate con il GBT. In questa implementazione la soglia non è un valore fisso ma viene calcolata in modo adattivo a ogni esecuzione: si costruisce l’istogramma delle probabilità assegnate ai candidati, lo si regolarizza tramite smoothing e si individua il primo minimo locale, che separa la massa dei candidati a bassa probabilità dalla coda di interesse. Quando la distribuzione delle probabilità non presenta un minimo locale netto, come accade sui dati reali del SRT — la cui distribuzione non è bimodale a differenza di quella ottenuta sui dati sintetici — il metodo ricade su una soglia di sicurezza fissata al 25° percentile delle probabilità stesse. In questo modo la soglia si adatta automaticamente alle caratteristiche statistiche dell’insieme di dati su cui il filtro viene eseguito, senza richiedere alcuna calibrazione manuale.

2.5.3 Selezione degli iperparametri UMAP

I parametri del Density Filter sono stati selezionati tramite una ricerca sistematica sullo spazio degli iperparametri UMAP, valutando ciascuna configurazione su tre metriche: la distanza euclidea tra il centroide della categoria *only-on-target* e il centroide della categoria *only-off-target* nello spazio UMAP (`centroid_dist`), il coefficiente di silhouette medio (`silhouette`), e la probabilità KDE media assegnata ai campioni *only-on-target*

(`p_ON_mean`). Le prime due metriche misurano la separabilità geometrica delle categorie nello spazio latente, mentre la terza misura direttamente la capacità del modello KDE di assegnare probabilità elevate ai candidati di interesse.

La ricerca è stata condotta in due iterazioni, entrambe sul medesimo dataset sintetico: la prima sulle feature originali (correlazione di Pearson a lag zero), la seconda dopo l'introduzione dell'estrattore NCC-max (Sezione 2.4.2), ricalcolando le feature con il nuovo estrattore e ripetendo la ricerca da capo.

La Tabella 2.2 riassume le prime dieci configurazioni della prima iterazione, ordinate per punteggio composito.

Rank	n_neighbors	min_dist	metrica	centroid	silhouette	p_ON_mean
1	100	0.3	correlation	22.403	0.853	0.0920
2	100	0.1	correlation	21.951	0.877	0.1719
3	50	0.3	correlation	21.577	0.859	0.0860
4	50	0.1	correlation	20.634	0.865	0.1535
5	15	0.3	correlation	20.526	0.857	0.0805
6	100	0.01	correlation	19.763	0.874	0.2297
7	25	0.3	correlation	19.303	0.850	0.0894
8	25	0.1	correlation	18.917	0.865	0.1487
9	15	0.1	correlation	17.637	0.856	0.1228
10	25	0.01	correlation	17.042	0.865	0.1918

Tabella 2.2: Prima iterazione (feature di Pearson a lag zero): prime dieci configurazioni UMAP ordinate per punteggio composito. Tutte utilizzano la metrica di correlazione.

Per la prima iterazione era stata selezionata la configurazione di Rank 2 (`n_neighbors`=100, `min_dist`=0.1, metrica di correlazione), che presenta il miglior coefficiente di silhouette tra le prime cinque (0.877) e un valore di `p_ON_mean` quasi doppio rispetto alla configurazione di Rank 1. Il risultato più evidente è però un altro: tutte le configurazioni nella top-10 utilizzano la metrica di correlazione, a differenza della metrica di Canberra adottata nel lavoro originale [1]. Questo suggerisce che, per le feature estratte dai dati SRT,

la metrica di correlazione cattura meglio le relazioni strutturali tra i vettori di feature rispetto alla metrica di Canberra, più sensibile alle differenze assolute tra valori piccoli. La Figura 2.6 mostra l’embedding della configurazione selezionata, con i contorni KDE sovrapposti.




Figura 2.6: Prima iterazione (feature di Pearson): spazio UMAP della configurazione selezionata con contorni KDE sovrapposti. In verde la categoria only-on-target (Cat. 42), in rosso la categoria only-off-target (Cat. 21).

La Tabella 2.3 riporta le migliori configurazioni della seconda iterazione, sulle feature NCC-max.


Rank	n_neighbors	min_dist	metrica	centroid	silhouette	p_ON_mean
1	25	0.1	correlation	5.081	0.788	0.2857
2	100	0.1	correlation	4.295	0.799	0.3779
3	25	0.01	correlation	3.259	0.752	0.3652
4	100	0.01	correlation	3.003	0.788	0.5038
5	25	0.1	cosine	0.820	0.295	0.3084
6	25	0.01	cosine	0.620	0.291	0.4014
7	100	0.1	cosine	0.611	0.257	0.3610
8	100	0.01	cosine	0.468	0.258	0.4708
9	25	0.1	canberra	0.279	0.054	0.2623
10	25	0.01	canberra	0.186	0.039	0.3268

Tabella 2.3: Seconda iterazione (feature NCC-max): configurazioni UMAP ordinate per punteggio composito.

La seconda iterazione conferma e rafforza il risultato sulla metrica: con le feature NCC-max il divario tra la metrica di correlazione e le alternative diventa netto, con distanze tra centroidi di un ordine di grandezza superiori e coefficienti di silhouette intorno a 0.79, contro valori inferiori a 0.30 per cosine e prossimi a zero per Canberra.

La configurazione selezionata per il modello finale è quella di Rank 1 della seconda iterazione: `n_neighbors=25`, `min_dist=0.1` e metrica di correlazione. La scelta è stata guidata dall'ispezione visiva degli embedding prodotti dalle configurazioni migliori: la 25/0.1 mostra la separazione più netta tra le categorie di riferimento e il resto della nube, giudizio confermato quantitativamente dalla distanza tra centroidi, la più alta della ricerca (5.081), con silhouette (0.788) e `p_ON_mean` (0.286) comparabili alle configurazioni immediatamente successive.

Il confronto visivo tra le due configurazioni migliori è riportato in Figura 2.7. L'embedding del modello finale, con i contorni KDE sovrapposti, è mostrato in Figura 2.8.



(a) Rank 1: n_neighbors=25, min_dist=0.1 (b) Rank 2: n_neighbors=100, min_dist=0.1

Figura 2.7: Confronto visivo tra le due migliori configurazioni della seconda iterazione (metrica di correlazione). La configurazione di Rank 1 (a) mostra una separazione più netta tra le categorie di riferimento e la nube centrale rispetto alla configurazione di Rank 2 (b), a supporto della selezione.




Figura 2.8: Seconda iterazione (feature NCC-max): spazio UMAP del modello finale con contorni KDE sovrapposti ($n_neighbors=25$, $min_dist=0.1$, metrica di correlazione). In verde la categoria only-on-target (Cat. 42), in rosso la categoria only-off-target (Cat. 21).

2.5.4 Risultati sui dati del SRT

Sull'insieme dei 180.242 candidati reali del SRT, la configurazione finale del filtro produce una distribuzione di probabilità $P(\text{only-on})$ priva del secondo modo netto osservato sui dati GBT del lavoro originale, come mostrato in Figura 2.9 (pannello sinistro): la massa dei candidati è concentrata in prossimità dello zero, con oltre 10^5 osservazioni nel primo bin, e si estende in una coda continua senza un minimo locale prominente che separi le due popolazioni. Il calcolo della soglia adattiva sull'istogramma regolarizzato individua tale minimo a 0,0987, marcato in figura, valore impiegato per discriminare i candidati promossi agli stadi successivi della pipeline. La logica di ricaduta al venticinquesimo percentile non

è stata attivata su questa esecuzione. Complessivamente, 1.452 candidati su 180.242 presentano argmax sulla categoria only-on-target; il pannello destro della Figura 2.9 isola questa sottopopolazione, evidenziando due modi separati dal minimo a 0,0987: dei 1.452 candidati, 1.089 (circa lo 0,60% del totale) superano anche la soglia di probabilità e vengono promossi agli stadi successivi della pipeline, mentre i restanti 363 hanno argmax compatibile ma probabilità inferiore alla soglia e vengono scartati.




Figura 2.9: Distribuzione di $P(\text{only-on})$ sui 180.242 candidati reali del SRT prodotta dal Density Filter. **Pannello sinistro:** distribuzione globale su tutti i candidati in scala logaritmica; la grande maggioranza si concentra in prossimità dello zero, mentre la coda destra si estende fino a $\sim 0,21$ senza un minimo netto tra le due popolazioni. **Pannello destro:** sottopopolazione dei 1.452 candidati con argmax sulla categoria only-on-target, in scala lineare; si distinguono due modi separati dal minimo locale a 0,0987 (linea verde tratteggiata), individuato dalla logica di soglia adattiva. Dei candidati con argmax compatibile, 1.089 superano la soglia e vengono promossi agli stadi successivi.

2.6 Frequency Filter

2.6.1 Descrizione del filtro nel lavoro di Pardo et al.

Il Frequency Filter assegna a ciascun candidato un punteggio di anomalia basato sulla rarità della sua frequenza centrale rispetto alla distribuzione delle frequenze osservate. L'intuizione alla base è che le frequenze maggiormente contaminate da RFI tendono a

essere sovrarappresentate nel dataset: concentrare la ricerca nelle regioni spettrali più quiete aumenta la probabilità di trovare candidati genuini.

Il filtro utilizza un ensemble di GMM [15] addestrati sulla distribuzione delle frequenze centrali dei candidati reali. Per aumentare la robustezza della stima viene adottata una strategia di *bagging*: più modelli GMM vengono addestrati su sottocampioni casuali del dataset, e il punteggio finale è la media delle densità stimate dall'ensemble. Il punteggio di anomalia è l'inverso di questa densità media — frequenze rare producono densità basse e quindi punteggi elevati.

Il filtro opera separatamente per ciascuna banda osservativa, con un numero di componenti GMM ottimizzato per banda. Nel lavoro originale vengono utilizzate le tre bande del GBT e di Parkes (L, S e 10 cm), con `n_components = 100`. Il punteggio prodotto viene infine normalizzato nell'intervallo $[0, 1]$ per consentire la combinazione con i punteggi degli altri filtri nella fase di ranking.

2.6.2 Ricalibrazione del numero di componenti

Il numero di componenti gaussiane ereditato dall'implementazione originale ($n_components=100$) si è rivelato sovradimensionato rispetto al volume di candidati prodotti dal Density Filter nelle due bande del SRT, con sintomi di sovradattamento osservabili sulla griglia $\{5, 10, 20, 50, 100\}$: la stabilità del ranking, misurata tramite correlazione di Spearman e overlap dei primi venti candidati tra modelli adiacenti, collassa nel passaggio da 20 a 50 e da 50 a 100 per entrambe le bande. È stato quindi selezionato il valore più alto stabile, $n_components=10$, per le bande C e K.

2.6.3 Risultati sui dati del SRT

Sui 1.089 candidati promossi dal Density Filter, il cut adattivo sui bin di frequenza più popolati è stato applicato secondo lo schema di Pardo et al. (top 5%, soglia minima di 200 candidati). Il filtro è stato addestrato e applicato in modo indipendente sulle due bande osservative, e all'interno di ciascuna banda ha assegnato a ogni candidato un punteggio di rarità basato sulla densità stimata alla sua frequenza centrale. La distribuzione degli score

risulta marcatamente diversa nelle due bande: in banda C si osserva una distribuzione sbilanciata verso lo zero con una coda visibile fino a 1.0 e alcuni outlier oltre 0.4, mentre in banda K la distribuzione è molto più compatta, con la quasi totalità dei candidati al di sotto di 0.1. Questo riflette la struttura sottostante delle occupazioni spettrali, mostrata in Figura 2.10: in banda C la distribuzione delle frequenze è bimodale, con picchi pronunciati a 4900–5000 MHz e 6700–7000 MHz e gap evidenti a 5500–6300 MHz, mentre in banda K l’occupazione è quasi uniforme nell’intervallo 18100–18500 MHz, con un unico gap netto attorno a 18270 MHz. L’implicazione operativa è che in banda C il GMM riesce a identificare regioni di frequenza significativamente più rare di altre, e i candidati nei gap o sui margini ricevono score elevati; in banda K, con un’occupazione spettrale quasi piatta, il filtro ha un margine discriminativo molto ridotto. La Figura 2.11 riporta la distribuzione degli score risultanti.




Figura 2.10: Distribuzione delle frequenze centrali dei candidati promossi dal Density Filter, separata per banda C (sinistra) e banda K (destra). In banda C la struttura è bimodale con gap netti; in banda K l’occupazione è quasi uniforme.




Figura 2.11: Distribuzione degli score del Frequency Filter, separata per banda C (sinistra) e banda K (destra), in scala logaritmica. In banda C la coda raggiunge 1.0; in banda K tutti i candidati restano al di sotto di 0.1.

2.7 Similarity Filter

2.7.1 Descrizione del filtro nel lavoro di Pardo et al.

Il Similarity Filter valuta la coerenza morfologica del segnale tra i pannelli ON e OFF di una cadenza. L'idea alla base è che un segnale di origine extraterrestre dovrebbe apparire simile a sé stesso nelle diverse osservazioni della stella bersaglio, e dissimile dalle osservazioni fuori bersaglio. Un'interferenza radio terrestre, al contrario, tende a presentarsi in modo incoerente o a comparire indistintamente in tutti i pannelli.

Per ragioni computazionali, prima di applicare il filtro la risoluzione degli spettrogrammi viene ridotta linearmente di un fattore 5 in frequenza e 2 in tempo, portandoli da 80×16 a 16×8 pixel. I sei pannelli ridotti vengono quindi proiettati in uno spazio bidimensionale tramite UMAP, addestrato su un sottocampione casuale del 20% dei candidati con metrica euclidea. In questo spazio, le osservazioni ON di un buon candidato si raggruppano tra loro e si separano dalle osservazioni OFF, mentre per un candidato RFI i pannelli risultano dispersi senza una struttura coerente.

Il punteggio di similarità è definito come il rapporto tra la distanza media tra le osservazioni ON e OFF nel piano UMAP e la distanza media tra le sole osservazioni ON.

Candidati con osservazioni ON molto simili tra loro e distanti dagli slot OFF ricevono punteggi elevati, prossimi a 1, mentre candidati incoerenti ricevono punteggi bassi.

2.7.2 Rappresentazione `cadence_raw`

A differenza del Density Filter e del Frequency Filter — che valutano rispettivamente la struttura di correlazione tra i pannelli e la rarità della frequenza centrale — il Similarity Filter opera direttamente sulla morfologia del segnale all'interno di ciascun pannello, confrontando la disposizione spaziale dell'energia nelle osservazioni ON e OFF. Questa differenza di scopo richiede una diversa rappresentazione dei dati in ingresso. Il preprocessing applicato in fase di caricamento dei candidati — normalizzazione temporale, rimozione del picco DC e correzione della risposta in banda tramite B-spline (Sezione 2.3.2) — è appropriato per i due filtri precedenti, ma la correzione di banda divide ciascun canale per il proprio andamento medio nel tempo, sopprimendo le componenti che si mantengono costanti in frequenza lungo l'osservazione. Tali componenti corrispondono però proprio alla morfologia di un segnale narrowband persistente, ovvero al pattern che il Similarity Filter deve essere in grado di riconoscere: applicare la correzione di banda al suo ingresso ne ridurrebbe la sensibilità verso i segnali di interesse.

Per questa ragione il Similarity Filter opera su una rappresentazione dedicata dei pannelli, distinta da quella impiegata dagli stadi precedenti. Ogni pannello viene normalizzato in modo indipendente nell'intervallo $[0, 1]$ sul proprio minimo e massimo, senza correzione della risposta in banda, preservando così le strutture narrowband persistenti su cui si fonda il confronto tra le osservazioni ON e OFF. Su questa rappresentazione il filtro applica poi la medesima procedura descritta nella Sezione 2.7.1: riduzione della risoluzione degli spettrogrammi, proiezione dei sei pannelli nello spazio UMAP e calcolo del punteggio di similarità a partire dalle distanze tra le osservazioni ON e OFF.

2.7.3 Verifica della sensibilità

La sensibilità del filtro così configurato è stata verificata riutilizzando le iniezioni a posizione fissa descritte nella Sezione 2.4.3, che riproducono un segnale narrowband persistente

presente nelle sole osservazioni ON. Sulla rappresentazione min-max il punteggio di similarità cresce in modo monotono con l'ampiezza del segnale iniettato — da valori prossimi a zero a SNR 5 fino a saturare in prossimità di 1 per $\text{SNR} \geq 20$ sulla finestra di produzione da 4096 canali — confermando che il filtro recupera correttamente i segnali esclusivamente on-target e ne misura la coerenza in funzione del rapporto segnale-rumore. Coerentemente con la formulazione del punteggio, la sensibilità resta più alta per segnali a basso tasso di deriva: quando il segnale si sposta in frequenza tra osservazioni ON consecutive, i pannelli ON diventano meno simili tra loro e il punteggio si riduce, un comportamento già presente nel filtro originale di Pardo et al. (2025) [1].

Un'ulteriore conferma proviene dall'ispezione dei candidati reali meglio valutati dal filtro. Le interferenze radio che compaiono indistintamente in tutti i pannelli ricevono punteggi di similarità bassi, coerentemente con l'assenza di una struttura ON/OFF coerente, mentre i punteggi più elevati corrispondono a segnali narrowband presenti nelle sole osservazioni ON. Tra questi rientra il candidato TIC 371234684 a 4859,98 MHz in banda C — la stessa finestra selezionata dall'estrattore NCC-max nel test di controllo della Sezione 2.4.3 — che presenta un segnale a banda stretta coerente nei tre pannelli ON; la revisione umana resta in ogni caso il passo conclusivo prima di qualunque conclusione sull'autenticità del segnale.

2.7.4 Risultati sui dati del SRT

L'applicazione del filtro ai 1.089 candidati promossi dal Density Filter produce una distribuzione di punteggi fortemente asimmetrica: un solo candidato raggiunge il valore massimo $S_{\text{sim}} = 1,00$ (coerenza ON/OFF massima possibile), 4 candidati restano sopra 0,5, 21 candidati restano sopra 0,1 e la grande maggioranza si attesta al di sotto di 0,05. Tutti i candidati con $S_{\text{sim}} \geq 0,5$ ricadono in banda K, coerentemente con il fatto che in questa banda la maggiore variabilità morfologica del segnale tra osservazioni ON e OFF offre al filtro maggiore margine discriminativo. La proiezione UMAP usata dal filtro mostra tre cluster principali con struttura curva (Figura 2.12), e i candidati a similarità più alta non si raggruppano in un'unica regione ma emergono come picchi locali in zone morfologicamente diverse del *manifold*, ovvero della superficie curva bidimensionale su cui

UMAP dispone i pannelli delle cadenze proiettandoli dallo spazio dei pixel. Il candidato con punteggio più alto in banda K è TIC 147576037 a 18197,55 MHz (Figura 2.13), che ricorre con altre tre finestre adiacenti dello stesso target (18258,71 MHz, $S_{\text{sim}} = 0,96$; 18227,49 MHz, $S_{\text{sim}} = 0,84$; 18145,00 MHz, $S_{\text{sim}} = 0,59$), suggerendo o un segnale persistente del target o un cluster locale di RFI. Il candidato con punteggio più alto in banda C è TIC 371234684 a 4859,98 MHz — lo stesso selezionato dall’estrattore NCC-max nel test di controllo della Sezione 2.4.3 e già mostrato in Figura 1.1 — il cui S_{sim} resta inferiore a 0,5 ma la cui coerenza incrociata tra due filtri indipendenti lo rende un punto di interesse per la revisione manuale. Con *revisione manuale* (o, equivalentemente, *ispezione visiva*) si intende, in questo lavoro e nel seguito, l’apertura dell’immagine PNG della cadenza e la verifica a occhio della presenza di un segnale a banda stretta coerente nei tre pannelli ON e della sua assenza nei tre pannelli OFF.




Figura 2.12: Spazio UMAP del Similarity Filter. Ogni punto nero rappresenta un pannello di uno dei candidati proiettato nello spazio bidimensionale del filtro; l'insieme di tutti i pannelli di tutti i candidati forma la nube di sfondo, che si sviluppa lungo tre estensioni curve corrispondenti a diversi regimi morfologici. Sopra la nube sono evidenziati i sei pannelli di due candidati di riferimento: in verde i sei pannelli del candidato con $S_{\text{sim}} = 1,00$ (coerenza ON/OFF massima), in rosso quelli del candidato con $S_{\text{sim}} = 0,00$ (coerenza ON/OFF nulla). La convenzione grafica riprende la Figura 7 di Pardo et al. (2025) [1].




Figura 2.13: Cadenza del candidato TIC 147576037 a 18197,55 MHz in banda K, top assoluto del Similarity Filter con $S_{\text{sim}} = 1,00$. Il segnale narrowband persistente è coerente nei tre pannelli ON e assente nei pannelli OFF.

2.8 Ranking

Il modulo di Ranking combina i punteggi prodotti dal Frequency Filter e dal Similarity Filter per selezionare i candidati più promettenti da sottoporre alla revisione manuale. Il Density Filter opera a monte come filtro binario — scarta o promuove i candidati — mentre i due filtri successivi producono punteggi continui che vengono utilizzati per stilare una graduatoria.

La selezione avviene costruendo quattro sottoinsiemi distinti. Il primo è composto dai candidati nel primo percentile per punteggio di frequenza per ciascuna combinazione stella–banda. Il secondo è composto dai candidati nel primo percentile per punteggio di

similarità. Il terzo, quello più promettente per la ricerca effettiva, seleziona i 1000 candidati migliori considerando entrambi i punteggi con pari peso. Il quarto è un sottoinsieme di controllo di 3000 candidati selezionati casualmente, utilizzato per validare l'efficacia dei filtri per confronto.

Nel lavoro originale, il sottoinsieme combinato raggiunge una percentuale di candidati di qualità pari a circa il 22%, contro il 14% del solo similarity score, il 7% del solo frequency score e meno del 3% del sottoinsieme casuale di controllo. Questo dimostra che i due punteggi contribuiscono in modo indipendente e complementare alla selezione dei candidati.

Il modulo di Ranking è stato riprodotto in questa implementazione senza modifiche architetturali rispetto al lavoro originale: i quattro sottoinsiemi sono costruiti con lo stesso criterio e con la stessa dimensione nominale, salvo l'adattamento automatico al pool effettivo quando questo è inferiore alla dimensione richiesta. I risultati prodotti sui dati del SRT sono discussi nel Capitolo 4, dove vengono messi a confronto con quelli ottenuti sostituendo il Density Filter con il filtro basato su autoencoder (Capitolo 3).

Capitolo 3

Applicazione autoencoder ai dati SETI

Questo capitolo descrive l'estensione della pipeline basata su autoencoder convoluzionale sviluppata al fine di valutare un possibile approccio alternativo al Density Filter. Ne vengono descritte la motivazione, l'architettura, la procedura di addestramento, la definizione del punteggio di anomalia e i risultati ottenuti.

3.1 Motivazione

Il Density Filter descritto nel Capitolo 2 rappresenta il primo stadio della pipeline di riferimento e riduce lo spazio di ricerca di circa due ordini di grandezza sui dati SRT (da $1,8 \cdot 10^5$ candidati iniziali a $\sim 10^3$ promossi). Tuttavia, la sua efficacia dipende dalla qualità dell'embedding UMAP e dalla scelta degli iperparametri di riduzione dimensionale: una proiezione bidimensionale non ottimale può comprimere informazioni rilevanti e rendere le regioni KDE meno separabili.

Come possibile approccio alternativo, è stato preso in considerazione l'impiego di un autoencoder convoluzionale [16] addestrato direttamente nello spazio delle feature originali, senza richiedere una proiezione intermedia. L'ipotesi di partenza era che un modello addestrato a ricostruire pattern statisticamente frequenti nei dati simulati fosse in grado di assegnare un errore di ricostruzione elevato ai candidati che si discostano da tali pattern — in particolare ai segnali presenti esclusivamente nei pannelli ON, che per definizione costituiscono le anomalie di interesse.

Questo approccio è concettualmente complementare al Density Filter: mentre quest'ultimo opera in uno spazio latente bidimensionale definito da UMAP, l'autoencoder opera direttamente nello spazio delle cadenze e apprende autonomamente una rappresentazione latente ottimizzata per la ricostruzione. L'implementazione completa del filtro autoencoder — architettura, procedura di addestramento in tre fasi e scoring — è disponibile nel repository del progetto¹. Il confronto tra i due approcci è oggetto del Capitolo 4.

3.2 Architettura del modello

Il modello adottato è un autoencoder convoluzionale simmetrico, ovvero una rete neurale composta da due sottoreti speculari: un *encoder* che comprime la cadenza in ingresso in una rappresentazione compatta a bassa dimensionalità (lo *spazio latente*), e un *decoder* che ricostruisce dalla rappresentazione compressa una cadenza della stessa dimensione dell'ingresso. Un modello di questo tipo, addestrato a minimizzare la differenza tra ingresso e ricostruzione, impara a rappresentare in modo efficiente i pattern ricorrenti nei dati di addestramento; una cadenza che si discosta da tali pattern verrà ricostruita male, e l'entità dell'errore di ricostruzione fornisce una misura naturale di anomalia. L'architettura non è fissata a priori ma è ricercata automaticamente tramite Keras Tuner [11], che esplora diverse combinazioni di iperparametri (numero di strati, numero di filtri, dimensione dello spazio latente e tasso di apprendimento) e seleziona quella con la migliore capacità di ricostruzione.

L'input della rete è una cadenza rappresentata come tensore di dimensioni $H \times W \times 6$, dove H è il numero di righe (bin temporali) e W è il numero di colonne (bin spettrali) di ciascun pannello, mentre i sei pannelli della cadenza vengono impilati lungo la terza dimensione e trattati come canali indipendenti dello stesso tensore — analogamente a come i tre canali RGB di un'immagine a colori vengono impilati e processati insieme. Questa scelta permette ai filtri convoluzionali dell'encoder di operare simultaneamente su tutte le sei osservazioni della cadenza in ogni posizione spettrale, apprendendo direttamente relazioni tra pannelli ON e OFF nello stesso passaggio.

¹<https://github.com/DavideDeplano/srt-anomaly-detection>

L'encoder è composto da uno o due strati convoluzionali (**Conv2D**), che applicano un banco di filtri a ciascuna regione locale del tensore in ingresso e producono *feature map* che evidenziano pattern spettrali ricorrenti (bordi, righe, gradienti). Ogni strato utilizza una funzione di attivazione ReLU, che introduce la non linearità necessaria a rappresentare pattern complessi, ed è seguito da un layer di **MaxPooling2D** con *stride* 2, che dimezza le dimensioni spaziali del tensore mantenendo solo il valore massimo in ciascuna finestra 2×2 : l'effetto è una progressiva compressione dell'informazione spaziale in una rappresentazione più densa e astratta. L'output dell'ultimo strato di pooling viene appiattito in un vettore unidimensionale (*flatten*) e proiettato in uno spazio latente denso di dimensione `latent_dim` tramite un layer completamente connesso **Dense**, che costituisce la rappresentazione compressa della cadenza.

Il decoder ricostruisce il tensore originale in modo speculare: un layer **Dense** espande la rappresentazione latente in un vettore delle dimensioni necessarie a essere rimodellato (**Reshape**) nella forma iniziale della cadenza, seguito da uno o due layer **Conv2DTranspose** con stride 2 che raddoppiano progressivamente le dimensioni spaziali ripristinando la risoluzione originale. Un layer **Conv2D** finale con funzione di attivazione sigmoide comprime i valori nell'intervallo $[0, 1]$ e produce l'output ricostruito, della stessa dimensione dell'input, direttamente confrontabile con la cadenza originale nel calcolo dell'errore di ricostruzione.

Gli iperparametri dell'architettura ricercati tramite Hyperband sono riassunti nella Tabella 3.1.

Iperparametro	Valori ricercati	Descrizione
<code>n_conv_layers</code>	$\{1, 2\}$	Numero di strati convoluzionali
<code>filters_1</code>	$\{16, 32\}$	Filtri nel primo strato Conv2D
<code>filters_2</code>	$\{32, 64\}$	Filtri nel secondo strato (se presente)
<code>latent_dim</code>	$\{32, 64, 128\}$	Dimensione dello spazio latente
<code>learning_rate</code>	$\{10^{-3}, 5 \cdot 10^{-4}, 10^{-4}\}$	Tasso di apprendimento Adam

Tabella 3.1: Spazio di ricerca degli iperparametri dell'autoencoder.

3.3 Addestramento

Il modello viene addestrato sull'insieme delle cadenze simulate, escludendo la categoria corrispondente al pattern esclusivamente on-target (categoria 42). Questa scelta è intenzionale: il modello impara a ricostruire tutti i pattern statisticamente frequenti nei dati simulati — rumore di fondo, RFI distribuita uniformemente, segnali presenti in combinazioni miste di pannelli ON e OFF — ma non il pattern anomalo di interesse. Di conseguenza, un candidato reale con segnale esclusivamente nei pannelli ON risulta difficile da ricostruire e ottiene un errore di ricostruzione elevato.

La funzione di loss utilizzata è l'errore quadratico medio (MSE) tra input e ricostruzione, minimizzato tramite l'ottimizzatore Adam. Il processo di addestramento è strutturato in tre fasi sequenziali, ciascuna con checkpoint su disco per garantire la riprendibilità in caso di interruzione.

Nella prima fase, Keras Tuner esegue una ricerca Hyperband sullo spazio degli iperparametri descritto nella Tabella 3.1, con un massimo di 50 *epoche* per trial (una *epoca* corrisponde a un intero passaggio del modello su tutto il training set) e *early stopping* con pazienza 3 sulla validation loss. L'early stopping interrompe l'addestramento quando la funzione di errore misurata su un insieme di validazione separato smette di migliorare, evitando che il modello continui ad adattarsi ai dati di addestramento oltre un punto di ottimo generalizzativo (*overfitting*); la *pazienza* indica il numero di epoche consecutive senza miglioramento tollerate prima dell'interruzione: pazienza 3 significa che l'addestramento si ferma dopo tre epoche consecutive senza riduzione della validation loss.

Nella seconda fase, una grid search su un sottocampione casuale del 20% del training set identifica la combinazione ottimale di numero massimo di epoche (esplorato tra 30, 50 e 80) e *batch size* (esplorato tra 64, 128 e 256), sempre con early stopping (pazienza 5, meno stringente della fase precedente perché il modello è ormai vicino alla configurazione finale e piccole fluttuazioni della validation loss non devono interrompere prematuramente l'addestramento). Il *batch size* è il numero di campioni processati dal modello prima di ciascun aggiornamento dei pesi: valori più bassi rendono l'addestramento più rumoroso ma spesso più capace di generalizzare, valori più alti lo stabilizzano ma richiedono più

memoria GPU.

Nella terza fase, il modello finale viene addestrato sull'intero training set con gli iperparametri e il piano di addestramento selezionati nelle fasi precedenti. Per evitare errori di memoria su GPU, il dataset di addestramento — che può superare i 32 GB — non viene mai caricato interamente in memoria: i campioni vengono letti dal disco tramite memory mapping e passati al modello un batch alla volta. L'implementazione completa dell'`AutoencoderFilter`, comprensiva della procedura di training in tre fasi e della calibrazione dello score, è disponibile nel repository del progetto.

3.4 Punteggio di anomalia

Il punteggio di anomalia di un candidato è definito come l'MSE normalizzato tra la cadenza originale e la sua ricostruzione prodotta dall'autoencoder. La normalizzazione è effettuata nell'intervallo $[0, 1]$ secondo la formula:

$$s = \text{clip} \left(\frac{\text{MSE} - \text{MSE}_{\min}}{\text{MSE}_{\max} - \text{MSE}_{\min}}, 0, 1 \right) \quad (3.1)$$

dove $\text{MSE}_{\min}$ e $\text{MSE}_{\max}$ sono stimati sulla distribuzione degli errori di ricostruzione sull'intero pool di candidati reali, in fase di calibrazione successiva all'addestramento. Poiché il modello è addestrato su cadenze simulate, mentre i candidati reali provengono da immagini PNG dell'SRT con caratteristiche statistiche differenti, una calibrazione diretta sui dati reali è necessaria per rendere la scala $[0, 1]$ rappresentativa del contesto operativo effettivo.

I due valori di calibrazione sono fissati rispettivamente al primo e al novantanovesimo percentile della distribuzione degli MSE sui candidati reali. La scelta dei percentili è motivata dalla forma della distribuzione: una calibrazione meno aggressiva, ad esempio p_5/p_{95} , comprime la coda alta provocando una saturazione marcata dei punteggi normalizzati e riduce la capacità discriminativa del filtro nella regione di interesse. L'impiego di p_1/p_{99} limita la saturazione a circa l'1% dei candidati su ciascuno dei due estremi e preserva la risoluzione dei punteggi sulla coda anomala.

Un punteggio elevato indica una cadenza difficile da ricostruire, ovvero anomala rispetto ai pattern appresi durante l'addestramento. I candidati con punteggio superiore a una soglia configurabile vengono promossi alla fase successiva della pipeline, in modo analogo ai candidati promossi dal Density Filter.

3.5 Risultati

L'autoencoder finale, addestrato con gli iperparametri selezionati dalla ricerca Hyperband (`n_conv_layers=2`, `filters_1=32`, `filters_2=64`, `latent_dim=128`, `learning_rate = 10-3`), è stato applicato all'intero insieme dei 180.242 candidati reali del SRT.

La calibrazione descritta nella Sezione 3.4 è stata eseguita sulla distribuzione degli MSE di ricostruzione calcolata sull'intero pool reale, ottenendo $\text{MSE}_{\min} = 0,0044$ (p_1) e $\text{MSE}_{\max} = 0,0271$ (p_{99}). La distribuzione degli MSE è risultata fortemente concentrata: il 50% dei candidati cade nell'intervallo $[0,0176, 0,0225]$, e la coda oltre il novantanovesimo percentile copre solo il 26% del range p_1 – p_{99} . Questo riflette il fatto che la grande maggioranza dei candidati reali presenta una morfologia compatibile con i pattern appresi dal modello (rumore di fondo, RFI a banda larga, pattern misti), mentre solo una piccola frazione si discosta in modo significativo.

Percentile MSE	Valore
p_1	0,0044
p_5	0,0093
p_{25}	0,0176
p_{50}	0,0203
p_{75}	0,0225
p_{90}	0,0243
p_{95}	0,0253
p_{99}	0,0271
$p_{99,9}$	0,0291

Tabella 3.2: Percentili della distribuzione degli MSE di ricostruzione sui 180.242 candidati reali del SRT. La calibrazione utilizza p_1 e p_{99} come estremi della scala dei punteggi.

Dopo la calibrazione, gli score normalizzati hanno distribuzione spostata verso l'alto (media 0,66, mediana 0,68), con saturazione contenuta: 1.803 candidati (circa l'1%) raggiungono il valore massimo 1,00 e un numero comparabile satura al valore minimo 0,00. Adottando una soglia di promozione $\text{ae_score} \geq 0,99$, vengono promossi 2.267 candidati su 180.242 (circa l'1,26% del totale), un numero confrontabile in ordine di grandezza con i 1.089 candidati promossi dal Density Filter (Sezione 2.5). La distribuzione del numero di candidati promossi a varie soglie è riportata nella Tabella 3.3.

Soglia <code>ae_score</code>	N. candidati	Percentuale
$\geq 0,50$	152.050	84,36%
$\geq 0,70$	89.456	49,63%
$\geq 0,80$	42.994	23,85%
$\geq 0,90$	12.313	6,83%
$\geq 0,95$	5.203	2,89%
$\geq 0,99$	2.267	1,26%

Tabella 3.3: Numero di candidati promossi dall’Autoencoder Filter al variare della soglia su `ae_score`, su un totale di 180.242 candidati reali. La soglia 0,99 è quella adottata nella configurazione di produzione.

La scelta della soglia a 0,99 è motivata da due considerazioni operative. La prima è il volume in uscita: soglie più basse promuovono decine di migliaia di candidati e rendono inefficace il ruolo di prima scrematura del filtro, vanificando il principio dell’approccio multi-stadio; soglie troppo alte, viceversa, restringono il pool al punto da rendere statisticamente poco significative le fasi successive di Frequency e Similarity Filter. La seconda è il confronto con il Density Filter: 0,99 produce un insieme di candidati di ordine di grandezza comparabile, condizione necessaria per un confronto bilanciato dei due workflow nel Capitolo 4. Le caratteristiche dei candidati promossi e il confronto con quelli prodotti dal Density Filter sono discussi nel capitolo successivo.

A completamento dei risultati principali, è stata condotta una verifica interna per delimitare il dominio di validità del modello sull’intero spazio dei 64 pattern ON/OFF del dataset simulato. Per ciascuna categoria è stato calcolato l’MSE di ricostruzione su 100 cadenze mai viste dal modello, ottenendo un rapporto tra la media di `cat42` e la media delle altre categorie pari a 1,38. Il valore aggregato, tuttavia, nasconde una struttura più informativa: sulle categorie con pochi pannelli attivi (`cat 0–15`) il modello ricostruisce con MSE molto basso e `cat42` risulta anche due ordini di grandezza superiore, mentre sulle categorie con molti pannelli attivi (`cat 39–63`) l’MSE di `cat42` è comparabile o inferiore. Ne emerge che il modello discrimina in base alla quantità complessiva di segnale presente

nella cadenza, non alla sua distribuzione tra pannelli ON e OFF: l'idea di escludere cat42 dall'addestramento — ragionevole nella sua formulazione originaria — non è risultata sufficiente a rendere il modello sensibile al pattern only-on-target come categoria strutturalmente distinta. Questa verifica costituisce essa stessa un risultato significativo che individua le proprietà su cui intervenire in futuro. Alla luce di tale esito e dei risultati sui dati reali, l'Autoencoder Filter deve essere considerato come un esperimento esplorativo utile a testare i limiti di un approccio alternativo di prima scrematura, e non come un modulo sostitutivo della pipeline principale. In particolare, le evidenze emerse mostrano che un approccio reconstruction-based basato sull'MSE globale non è, nella forma corrente, adatto a discriminare cadenze con pattern only-on-target.

Capitolo 4

Confronto tra modello originale e modello proposto

Questo capitolo confronta i due workflow descritti nei capitoli precedenti: il workflow originale di Pardo et al. (2025) [1], adattato al SRT (Capitolo 2), e il workflow proposto in cui il primo stadio è sostituito dall’Autoencoder Filter (Capitolo 3). I due workflow condividono gli stessi stadi successivi — Frequency Filter, Similarity Filter e modulo di ranking — ma differiscono nello stadio di selezione iniziale, che ne determina il pool di candidati promossi. Il confronto è quindi articolato in due livelli: i pool di candidati promossi dai due primi stadi, e i risultati prodotti applicando gli stessi stadi successivi a tali pool.

4.1 Impostazione del confronto

Entrambi i filtri operano sullo stesso insieme di 180.242 candidati reali del SRT (Sezione 2.3.2) e producono in uscita un sottoinsieme di candidati promossi agli stadi successivi della pipeline. Il Density Filter, descritto nella Sezione 2.5, promuove 1.089 candidati (0,60%) sulla base della probabilità $P(\text{only-on})$ stimata nello spazio UMAP, con una soglia adattiva calcolata sull’istogramma regolarizzato della distribuzione. L’Autoencoder Filter, descritto nella Sezione 3.5, promuove 2.267 candidati (1,26%) sulla base dell’erro-

re di ricostruzione normalizzato, con una soglia fissa pari a 0,99 scelta per ottenere un volume in uscita dello stesso ordine di grandezza di quello del Density Filter.

I due filtri operano su rappresentazioni del segnale strutturalmente differenti. Il Density Filter agisce sul vettore di feature di cross-correlazione tra coppie di pannelli, proiettato in uno spazio UMAP bidimensionale; cattura quindi anomalie definite dalla *struttura di correlazione* tra le sei osservazioni della cadenza. L’Autoencoder Filter agisce direttamente sul tensore della cadenza nello spazio dei pixel e seleziona i candidati sulla base del loro scostamento dai pattern di ricostruzione appresi sul dataset simulato.

4.2 Confronto dei pool promossi

Confrontando direttamente gli identificativi dei candidati promossi dai due filtri, l’intersezione tra il pool Density e il pool Autoencoder è di soli 10 candidati. Questo valore rappresenta circa lo 0,9% del pool Density e lo 0,4% del pool Autoencoder, e corrisponde a un’unione di 3.346 candidati distinti. La Tabella 4.1 riassume i numeri.

Insieme	N. candidati
Pool Density ($P(\text{only-on}) \geq 0,0987$)	1.089
Pool Autoencoder ($\text{ae_score} \geq 0,99$)	2.267
Intersezione (presenti in entrambi i pool)	10
Solo Density (esclusivi)	1.079
Solo Autoencoder (esclusivi)	2.257
Unione	3.346

Tabella 4.1: Confronto dei pool di candidati promossi dai due filtri di prima scrematura. L’intersezione è marginale rispetto alle dimensioni dei singoli pool, indicando che i due filtri promuovono candidati in larga parte disgiunti.

L’entità dell’intersezione — meno dell’1% in entrambe le direzioni — è il risultato più rilevante del confronto sui pool: i due filtri operano in modo *quasi ortogonale*, selezionando candidati che si trovano in regioni distinte dello spazio delle cadenze. Questo è coerente

con la motivazione esposta nella Sezione 3.1, in cui l’Autoencoder Filter è stato introdotto come approccio complementare al Density Filter, non come sua replica. Da un punto di vista operativo, l’ortogonalità implica che l’unione dei due pool (3.346 candidati, l’1,86% del totale) costituisce un sottoinsieme più ampio e diversificato di candidati anomali rispetto a quanto ciascun filtro raggiungerebbe individualmente, e che ciascuno dei due workflow è in grado di intercettare segnali di interesse a cui l’altro è cieco.

Per inquadrare il significato qualitativo della differenza, è utile considerare i punteggi assegnati dall’Autoencoder Filter (nel seguito indicati come `ae_score`) ai candidati promossi dal Density Filter. La distribuzione degli `ae_score` sui 1.089 candidati Density-passati ha media 0,625 e mediana 0,682, valori leggermente inferiori alla media e alla mediana globali (0,663 e 0,699 rispettivamente); solo 57 di essi superano la soglia 0,90, e solo 10 superano 0,99. In altre parole, i candidati promossi dal Density Filter non si distinguono dalla popolazione globale per il punteggio assegnato dall’Autoencoder, e raramente lo raggiungono ai livelli eccellenti: il Density seleziona candidati anomali secondo un criterio (correlazione) che è correlato in modo debole con la nozione di anomalia colta dall’Autoencoder (errore di ricostruzione). I due filtri vedono, di fatto, anomalie diverse.

4.3 Confronto dei risultati Frequency e Similarity

L’applicazione del Frequency Filter e del Similarity Filter al pool di 2.267 candidati promossi dall’Autoencoder Filter è stata condotta con la stessa configurazione utilizzata sul pool Density (Sezioni 2.6 e 2.7): due bande separate (C e K), `n_components` = 10 per il Frequency Filter, rappresentazione `cadence_raw` min-max per il Similarity Filter.

La distribuzione degli score di frequenza sul pool Autoencoder si concentra prevalentemente a valori bassi (`frequency_score` < 0,1 per la grande maggioranza dei candidati), con una coda che raggiunge 1,0 in banda C. La distribuzione degli score di similarità presenta invece un comportamento qualitativamente diverso rispetto al pool Density: la mediana di S_{sim} è 0,11 contro 0,001 del pool Density, il terzo quartile è 0,17 contro 0,002, e 43 candidati superano la soglia 0,5 contro appena 3 del pool Density. Il pool Autoencoder produce quindi punteggi di similarità mediamente più alti, ma questa maggiore diffusione

non corrisponde a un guadagno discriminativo: sul pool Density i tre candidati sopra 0,5 formavano un cluster di finestre adiacenti dello stesso target, associato al candidato only-on-target di riferimento TIC 147576037, mentre sul pool Autoencoder l'unico candidato con $S_{\text{sim}} = 1,00$ è di natura diversa, come discusso nel seguito.

Pool	Score	Med.	Q3	Max	N$\geq$0,5	N$\geq$0,99
Density ($N = 1089$)	frequency	0,005	0,011	1,000	8	1
	similarity	0,001	0,002	1,000	3	1
Autoencoder ($N = 2267$)	frequency	0,001	0,005	1,000	6	1
	similarity	0,107	0,169	1,000	43	1

Tabella 4.2: Distribuzione degli score dei filtri di frequenza e similarità calcolati sui due pool di candidati promossi rispettivamente dal Density Filter e dall'Autoencoder Filter. Per ciascuno score sono riportati mediana, terzo quartile, massimo e il numero di candidati con score $\geq 0,5$ e $\geq 0,99$.

L'unico candidato con $S_{\text{sim}} = 1,00$ nel pool Autoencoder è TIC 154872375 a 6708,31 MHz in banda C. L'ispezione visiva della cadenza corrispondente non rivela alcun segnale narrowband coerente nei pannelli ON: la cadenza è compatibile con rumore di fondo, e il punteggio di similarità saturato è riconducibile a correlazioni spurie del rumore stesso all'interno dello spazio UMAP del filtro. Questo risultato è coerente con quanto già osservato dall'ispezione della top-10 per `ae_score` sul pool Autoencoder, in cui le prime dieci finestre appartengono tutte a un unico target (TIC 103633434) in una regione contigua di banda K (da 18094 a 18140 MHz), configurazione tipica di un cluster di interferenza radio persistente. Il pool Autoencoder è dunque dominato, ai vertici della graduatoria, da agglomerati di finestre che condividono lo stesso target e occupano regioni spettrali contigue: un pattern strutturalmente diverso da quello che i filtri successivi sono progettati per riconoscere e valorizzare.

Alla scala del target, TIC 154872375 conta 108 finestre promosse dall'Autoencoder Filter, distribuite tra le due bande in un intervallo compreso tra 6580 e 18470 MHz. TIC 147576037, il target di riferimento identificato dal workflow Density, conta invece 8

finestre nel pool Autoencoder, con score di frequenza compresi tra 0,005 e 0,027 e score di similarità compresi tra 0,03 e 0,10: valori sensibilmente inferiori a quelli assegnati dal workflow Density alle stesse cadenze, che nel proprio pool le portava nella regione $S_{\text{sim}} \in [0,59, 1,00]$. Il segnale only-on-target riconosciuto dal workflow Density non emerge quindi come tale nel workflow Autoencoder, e viene disperso nella coda inferiore delle distribuzioni degli score.

4.4 Confronto dei campioni di ranking

Il modulo di ranking (Sezione 2.8) applicato al pool Autoencoder produce quattro campioni con la medesima logica descritta per il workflow Density: primo percentile per punteggio di frequenza, primo percentile per punteggio di similarità, top-K combinato per la media geometrica dei due punteggi, e campione di controllo casuale. Il criterio del primo percentile è applicato indipendentemente a ciascuna combinazione target-banda del pool: per ogni combinazione viene selezionato un numero di candidati pari a $k = \max(1, \lceil 0,01 \cdot n \rceil)$, dove n è il numero di candidati della combinazione con punteggio valido; le combinazioni prive di candidati con punteggio valido non contribuiscono al campione. La cardinalità dei due campioni per percentile non coincide quindi in generale con il numero di combinazioni presenti nel pool: può risultare inferiore quando una combinazione viene esclusa per assenza di punteggi validi, o superiore quando una combinazione contiene un numero di candidati sufficiente ($n \geq 101$) da fare scattare l'arrotondamento del primo percentile a due unità. Il pool Autoencoder contiene 78 combinazioni target-banda, una delle quali viene esclusa per assenza di punteggi validi, e i due campioni per percentile risultano composti da 77 candidati ciascuno (39 in banda C e 38 in banda K). Il pool Density contiene 79 combinazioni target-banda, tutte con punteggi validi: una di esse contiene un numero di candidati sufficiente a produrre $k = 2$, e i due campioni per percentile del workflow Density contano di conseguenza 80 candidati ciascuno (40 in banda C e 40 in banda K). Il campione top-K combinato dipende invece dalla numerosità complessiva del pool: nel workflow Autoencoder raggiunge la dimensione nominale di 1000 candidati (394 in banda C e 606 in banda K), mentre nel workflow Density il pool disponibile è di soli 842

candidati con punteggio valido, e il campione coincide con l'intero pool (273 in banda C e 569 in banda K). La Tabella 4.3 riassume la composizione dei tre campioni non casuali per entrambi i workflow.

Workflow	Campione	Totale	Banda C	Banda K
Density	Primo percentile frequenza	80	40	40
Density	Primo percentile similarità	80	40	40
Density	Top-K combinato	842	273	569
Autoencoder	Primo percentile frequenza	77	39	38
Autoencoder	Primo percentile similarità	77	39	38
Autoencoder	Top-K combinato	1000	394	606

Tabella 4.3: Composizione dei tre campioni non casuali prodotti dal modulo di ranking per i due workflow.

Il campione top-K combinato è dominato da un numero ridotto di target ricorrenti: le prime cinque sorgenti per numero di finestre incluse — TIC 176860064, TIC 368536386, TIC 154872375, TIC 378291076 e TIC 125442121 — coprono complessivamente 291 finestre delle 1000 selezionate, ovvero circa il 29% del campione. Questa concentrazione riflette la stessa struttura a cluster osservata a monte del ranking, e indica che il campione di uscita del workflow Autoencoder è composto in larga parte da finestre spettralmente contigue dello stesso target, morfologicamente compatibili con interferenza radio persistente.

Il confronto con i corrispondenti campioni del workflow Density mostra un'assenza sistematica di sovrapposizione. I campioni per primo percentile di frequenza e di similarità non condividono alcun candidato tra i due workflow (0 candidati in comune su 77 nell'uno e 80 nell'altro). Il campione top-K combinato conta soltanto quattro candidati in comune tra i due workflow: TIC 368536386 a 4855,90 MHz in banda C, TIC 147576037 a 18114,79 MHz, TIC 148782377 a 18150,59 MHz e TIC 378291076 a 18418,61 MHz, gli altri tre in banda K. Per tutti e quattro i candidati in comune gli score di frequenza e di similarità restano bassi in entrambi i workflow ($\text{frequency_score} \lesssim 0,02$, $S_{\text{sim}} \lesssim 0,07$), e

l’ispezione visiva delle cadenze corrispondenti non rivela in alcun caso un segnale narrowband coerente presente esclusivamente nei pannelli ON: tutte e quattro le finestre sono compatibili con rumore di fondo o con interferenza radio a bassa intensità. In particolare, la finestra di TIC 147576037 a 18114,79 MHz — unico target di riferimento del workflow Density presente anche nell’intersezione — non contiene il segnale narrowband persistente osservato invece nella finestra a 18197,55 MHz dello stesso target, individuata dal Similarity Filter come top assoluto con $S_{\text{sim}} = 1,00$ (Sezione 2.7).

4.5 Discussione

I risultati delle sezioni precedenti mostrano che l’ortogonalità tra i due workflow non si limita ai pool di prima scrematura (Sezione 4.2) ma si estende a tutti gli stadi successivi della pipeline: nei campioni per primo percentile di frequenza e di similarità non compare alcun candidato in comune, e nel campione top-K combinato l’intersezione si riduce a quattro candidati con score marginali in entrambi i ranking. L’ispezione visiva delle cadenze corrispondenti costituisce il passo conclusivo del confronto, e ne determina l’interpretazione operativa.

Il workflow Density identifica un candidato con caratteristiche compatibili con il pattern only-on: TIC 147576037 a 18197,55 MHz in banda K, che emerge come top assoluto del Similarity Filter con $S_{\text{sim}} = 1,00$ e ricorre con altre due finestre adiacenti dello stesso target sopra 0,5. L’ispezione visiva della cadenza corrispondente, riportata in Figura 2.13, conferma la presenza di un segnale narrowband coerente nei tre pannelli ON e assente nei pannelli OFF. Il workflow Autoencoder, applicato allo stesso insieme di dati e con gli stessi stadi successivi, non riconosce questo candidato: ne include 8 finestre nel proprio pool con score bassi, e non lo promuove ai vertici di nessuno dei tre campioni per punteggio. Il candidato che il workflow Autoencoder porta al vertice del ranking di similarità è invece TIC 154872375 a 6708,31 MHz in banda C, la cui cadenza è mostrata in Figura 4.1: l’ispezione visiva non rivela alcun segnale narrowband coerente nei pannelli ON, e la cadenza è compatibile con rumore di fondo. Il punteggio di similarità saturato è quindi riconducibile a correlazioni spurie del rumore all’interno dello spazio UMAP del

filtro, non a un segnale only-on effettivamente presente.




Figura 4.1: Cadenza di TIC 154872375 a 6708,31 MHz in banda C, top assoluto del Similarity Filter nel workflow Autoencoder ($S_{\text{sim}} = 1,00$). Da confrontare con la Figura 2.13, top assoluto del Similarity Filter nel workflow Density.

La stessa lettura si estende all'intersezione dei due workflow. Le dieci finestre condivise dai pool di prima scrematura e le quattro finestre condivise dal campione top-K combinato sono state ispezionate visivamente una a una: in nessun caso è stato identificato un segnale narrowband coerente esclusivamente nei pannelli ON. In particolare, la finestra di TIC 147576037 a 18114,79 MHz, unica occorrenza del target di riferimento del workflow Density presente anche nell'intersezione del top-K combinato, non contiene il segnale osservato invece nella finestra a 18197,55 MHz dello stesso target: si tratta di una finestra adiacente dominata dal rumore di fondo, che è entrata nell'intersezione per una coincidenza di score bassi in entrambi i ranking.

Il quadro complessivo che emerge è coerente con la motivazione originaria dell'Autoencoder Filter, ma ne inverte l'esito atteso. L'ipotesi di partenza (Sezione 3.1) era che un modello addestrato a ricostruire pattern statisticamente frequenti nei dati simulati assegnasse un errore di ricostruzione elevato ai candidati anomali, e in particolare a quelli con struttura only-on. L'esito osservato mostra che il modello effettivamente promuove candidati diversi da quelli selezionati dal Density Filter, ma tali candidati non corrispondono al pattern only-on: sono agglomerati di finestre spettralmente contigue dello stesso target, tipicamente compatibili con interferenza radio persistente, che il modello riconosce come anomali rispetto ai pattern simulati senza però discriminare la coerenza ON/OFF interna alla cadenza. Il limite non è riconducibile al solo divario tra dominio di addestramento e dominio di applicazione: la verifica interna sull'intero spazio dei 64 pattern del dataset simulato (Sezione 3.5) mostra che il modello discrimina in base alla quantità complessiva di segnale presente nella cadenza, non alla sua distribuzione tra pannelli ON e OFF, e non riconosce il pattern only-on come categoria strutturalmente distinta neppure sul dominio in cui è stato addestrato. La causa primaria è la funzione obiettivo: l'errore quadratico medio sull'intero tensore aggrega uniformemente l'errore su tutti i pixel ed è dominato dal rumore di fondo, senza isolare il segnale narrowband che occupa una frazione trascurabile della cadenza.

Il workflow Density, per contro, opera su una feature (la struttura di correlazione tra pannelli) che è definita esplicitamente in modo da rispondere al pattern only-on, e la sua efficacia nell'identificare TIC 147576037 lo conferma. Da un punto di vista operativo, il confronto suggerisce che il Density Filter resta la scelta appropriata come primo stadio di scrematura per la ricerca only-on nella pipeline studiata, mentre l'Autoencoder Filter, nella sua forma corrente, costituisce un esperimento esplorativo di reconstruction-based di cui i risultati mostrano quantitativamente i limiti. Le direzioni di sviluppo che tengono conto di questo esito — in particolare l'addestramento del filtro su cadenze reali del SRT con signal injection controllata, in modo da coprire il gap di dominio tra il modello di addestramento sintetico e la morfologia dei candidati reali — sono discusse nel Capitolo 5.

Capitolo 5

Conclusione e sviluppi futuri

5.1 Riepilogo del lavoro

Il lavoro ha verificato l'applicabilità della pipeline di anomaly detection di [1] a un contesto osservativo differente da quello originale rappresentato dai dati del Sardinia Radio Telescope e ha introdotto alcuni adattamenti metodologici e implementativi motivate dalle differenze strumentali e dalla struttura del dataset.

L'adattamento ha riguardato più livelli della pipeline. La generazione delle cadenze sintetiche è stata riformulata per riflettere meglio la variabilità del rumore strumentale del SRT. La soglia del Density Filter è stata resa adattiva per tener conto della diversa distribuzione dei candidati reali del SRT. Il Frequency Filter è stato ricalibrato separatamente per le due bande operative. Il Similarity Filter è stato modificato in modo da preservare le strutture narrowband persistenti su cui il filtro fonda il confronto tra osservazioni ON e OFF.

Il contributo metodologico principale è l'introduzione dell'estrattore NCC-max, che generalizza la feature di correlazione impiegata nel lavoro di Pardo et al. sostituendo il confronto a spostamento nullo con il massimo della cross-correlazione normalizzata entro una finestra limitata di traslazioni relative. Tale modifica introduce una tolleranza a piccoli disallineamenti in frequenza da un pannello all'altro e consente di rappresentare in modo più realistico il comportamento di una sorgente celeste reale. Il test di iniezione controllata ha mostrato che l'estrattore NCC-max è in grado di rilevare segnali con deriva

non nulla, a differenza dell'estrattore originario.

Un secondo risultato riguarda la scelta della metrica di proiezione UMAP. L'analisi condotta mostra che la metrica di *Correlazione* separa le categorie di riferimento in modo più efficace rispetto alle alternative considerate. Questo suggerisce che la scelta della metrica non è trasferibile tra contesti osservativi e va ricalibrata sui dati operativi specifici.

Il lavoro ha esplorato inoltre un'estensione della pipeline basata su un autoencoder convoluzionale, valutato come alternativa al Density Filter. Il confronto tra i due approcci ha mostrato che il modello seleziona candidati in larga parte distinti da quelli promossi dal Density Filter, ma senza far emergere il pattern only-on come categoria strutturalmente distinta neppure sul dominio in cui è stato addestrato. L'analisi effettuata sul dataset simulato ha mostrato che il modello discrimina principalmente in base alla quantità di segnale presente nella cadenza, piuttosto che in base al pattern only-on. L'Autoencoder Filter va, di conseguenza, considerato come un esperimento esplorativo che ha consentito di individuare i limiti di un approccio alternativo, anziché come un modulo sostitutivo della pipeline principale.

Infine è stato effettuato un test con un classificatore supervisionato basato su Random Forest, addestrato su feature scalari estratte dalle cadenze. Il modello ha mostrato buone prestazioni sul dominio sintetico, ma sui candidati reali del SRT evidenzia un mancato trasferimento dal dominio di addestramento a quello di applicazione. Tale risultato conferma la centralità del divario tra dati sintetici e dati reali come problema aperto per l'estensione della pipeline a modelli supervisionati o reconstruction-based.

5.2 Limitazioni

Alcuni aspetti del lavoro presentano limitazioni che è opportuno esplicitare, sia per contestualizzare correttamente i risultati sia per motivare le direzioni di sviluppo discusse nella sezione successiva.

La validazione sperimentale dell'estrattore NCC-max è stata condotta tramite iniezione controllata su una singola cadenza reale e a un singolo tasso di deriva. Questo test

costituisce un controllo positivo sulla sensibilità del modello, ma non una caratterizzazione statistica esaustiva del suo comportamento al variare delle condizioni osservative.

L’addestramento dei modelli si fonda interamente su cadenze sintetiche, generate secondo un modello idealizzato che non riproduce la varietà morfologica dei segnali astrofisici reali né quella delle interferenze radio caratteristiche del sito osservativo. Questa scelta è metodologicamente coerente con l’approccio di [1], ma mantiene un divario tra il regime di addestramento e quello di inferenza che è opportuno esplicitare. L’esperimento preliminare con classificatore Random Forest mostra che questo divario ha effetti concreti: modelli con accuratezza elevata sul dominio sintetico producono sui candidati reali distribuzioni di punteggi sostanzialmente indistinguibili tra sottoinsiemi promossi dal Density Filter e resto del dataset.

La verifica di trasferibilità della pipeline è stata condotta su un singolo strumento — il SRT — a partire dalla configurazione calibrata sul Green Bank Telescope. Il risultato mostra che l’adattamento a un nuovo contesto è possibile, ma un solo caso non è sufficiente a caratterizzare la trasferibilità della pipeline come proprietà generale della metodologia.

Infine, la selezione automatica dei candidati va intesa come un passo di riduzione dello spazio di ricerca, non come una decisione conclusiva sull’autenticità dei segnali. L’ispezione finale dei candidati promossi resta affidata alla revisione umana, che rappresenta un onere non trascurabile e potenzialmente scalabile solo entro certi limiti al crescere dei volumi di dati.

5.3 Sviluppi futuri

Le limitazioni discusse nella sezione precedente aprono altrettante direzioni di lavoro futuro, alle quali si aggiungono due prospettive di consolidamento infrastrutturale della pipeline.

- **Caratterizzazione statistica della sensibilità.** Estendere la validazione dell’estrattore NCC-max, e più in generale del Density Filter, a un insieme rappresentativo di cadenze reali del SRT. Le iniezioni andrebbero distribuite su una griglia sistematica di tassi di deriva e ampiezze del segnale, in modo da costruire curve di comple-

tezza in funzione del rapporto segnale-rumore e della deriva. Il risultato sarebbe una descrizione quantitativa di quali segnali la pipeline è effettivamente in grado di rilevare, e a quale confidenza.

- **Arricchimento del generatore sintetico.** Modificare il `SimulationGenerator` in modo che, all'interno di una stessa cadenza, il segnale iniettato nei tre pannelli ON derivi coerentemente nel tempo: la sua posizione in ciascun pannello dovrebbe essere determinata da quella nel pannello precedente secondo il tasso di deriva scelto, invece di essere campionata in modo indipendente. Questo intervento non altera la natura schematica delle cadenze sintetiche, ma riduce il divario tra il modello di addestramento e il comportamento osservativo atteso di una sorgente reale.
- **Addestramento su cadenze reali con signal injection controllata.** Il divario tra dominio sintetico e dominio reale documentato nel Capitolo 4 e nell'esperimento Random Forest riepilogato nella Sezione 5.1 suggerisce come direzione naturale l'iniezione controllata di segnali sintetici direttamente sopra cadenze reali del SRT, in luogo dell'uso esclusivo di un rumore di fondo pre-registrato. Un dataset di addestramento costruito in questo modo preserverebbe la morfologia autentica del rumore di ricezione, dell'ambiente RFI e delle variazioni di temperatura di sistema del sito osservativo, e permetterebbe ai filtri supervisionati e reconstruction-based di apprendere direttamente il contrasto tra il pattern only-on iniettato e il rumore effettivamente osservato. L'estensione richiederebbe una procedura dedicata di selezione delle cadenze reali di base per l'iniezione e una validazione incrociata separata sull'insieme delle cadenze reali non modificate.
- **Ottimizzazione delle prestazioni computazionali.** L'esecuzione attuale della pipeline sui 180.242 candidati del SRT è sostenibile su una singola postazione, ma già in questo regime il caricamento e il preprocessing delle cadenze rappresentano una frazione significativa del tempo totale. In scenari operativi comparabili a quelli del programma Breakthrough Listen, dove il volume di dati cresce di ordini di grandezza, sarebbe necessario intervenire sull'infrastruttura di esecuzione — paral-

lelizzazione su più nodi, accelerazione dei modelli di deep learning, formati binari di archiviazione al posto delle immagini — per mantenere la pipeline utilizzabile.

- **Riproduzione su altri radiotelescopi INAF.** Applicare la pipeline ai dati di altri strumenti radioastronomici dell'Istituto Nazionale di Astrofisica, in particolare Medicina e Noto, permetterebbe di trasformare la trasferibilità della metodologia da singolo caso studio a proprietà validata su più strumenti. Ciascun nuovo contesto osservativo consente inoltre di identificare eventuali componenti della pipeline che richiedono adattamenti ulteriori, contribuendo a distinguere le scelte metodologiche universalmente valide da quelle specifiche di uno strumento.
- **Integrazione del SRT in un programma SETI continuativo.** Inserire il SRT in un programma osservativo SETI sistematico, con archiviazione strutturata delle cadenze e applicazione regolare della pipeline al flusso di dati prodotti, consentirebbe di trasformare il presente lavoro da esperimento su un dataset chiuso a componente di un'infrastruttura di ricerca operativa. Un'integrazione di questo tipo estenderebbe significativamente la copertura spettrale complessiva dei programmi SETI attivi, grazie alla complementarità delle bande operative del SRT rispetto a quelle di GBT e Parkes.

Bibliografia

- [1] S. Pardo, D. Poznanski, S. Croft, A. P. Siemion, and M. Lebofsky, “Using anomaly detection to search for technosignatures in breakthrough listen observations,” *The Astronomical Journal*, vol. 170, no. 1, p. 12, 2025.
- [2] I. Prandoni, M. Murgia, A. Tarchi *et al.*, “The sardinia radio telescope: From a technological project to a radio observatory,” *Astronomy & Astrophysics*, vol. 608, p. A40, 2017.
- [3] S. P. Worden, J. Drew, A. Siemion *et al.*, “Breakthrough listen – a new search for life in the universe,” *Acta Astronautica*, vol. 139, pp. 98–101, 2017.
- [4] J. E. Enriquez and D. C. Price, “turboSETI: Python-based SETI search algorithm,” 2019, astrophysics Source Code Library, ascl:1906.006.
- [5] J. E. Enriquez, A. Siemion, G. Foster *et al.*, “The Breakthrough Listen search for intelligent life: 1.1–1.9 GHz observations of 692 nearby stars,” *The Astrophysical Journal*, vol. 849, no. 2, p. 104, 2017.
- [6] B. Brzycki, A. P. V. Siemion, S. Croft *et al.*, “Narrow-band signal localization for SETI on noisy synthetic spectrogram data,” *Publications of the Astronomical Society of the Pacific*, vol. 132, no. 1017, p. 114501, 2020.
- [7] P. X. Ma, C. Ng, L. Rizk *et al.*, “A deep-learning search for technosignatures from 820 nearby stars,” *Nature Astronomy*, vol. 7, pp. 492–502, 2023.

- [8] B. Jacobson-Bell, S. Croft, C. Choza *et al.*, “Clustering-based identification of morphological outliers in narrow-band SETI searches,” *The Astronomical Journal*, vol. 169, p. 206, 2025.
- [9] L. McInnes, J. Healy, and J. Melville, “Umap: Uniform manifold approximation and projection for dimension reduction,” *arXiv preprint arXiv:1802.03426*, 2018.
- [10] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, “Scikit-learn: Machine learning in python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [11] M. Abadi, A. Agarwal, P. Barham *et al.*, “Tensorflow: Large-scale machine learning on heterogeneous systems,” 2015, software available from tensorflow.org.
- [12] D. C. Price, J. E. Enriquez, Y. Chen, and M. Siebert, “Blimpy: Breakthrough listen i/o methods for python,” *Journal of Open Source Software*, vol. 4, no. 40, p. 1554, 2019.
- [13] B. Brzycki, A. P. V. Siemion, S. Croft *et al.*, “Setigen: Simulating radio technosignatures for the search for extraterrestrial intelligence,” *The Astronomical Journal*, vol. 163, no. 5, p. 222, 2022.
- [14] P. Bolli, A. Orlati, L. Stringhetti *et al.*, “Sardinia radio telescope: General description, technical commissioning and first light,” *Journal of Astronomical Instrumentation*, vol. 4, no. 3-4, p. 1550008, 2015.
- [15] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.
- [16] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.

Ringraziamenti

Questa laurea arriva tardi rispetto ai tempi convenzionali, e non è arrivata in linea retta. Fra il diploma e oggi ci sono stati anni di lavoro in ristorazione e non solo, due esperienze a Londra a distanza di anni, un percorso formativo alternativo che, pur breve, mi ha restituito la voglia di studiare, e infine la decisione di lasciare il lavoro per iscrivermi all'università a trentadue anni e riprendere gli studi in un ambito in cui credevo davvero. Ogni deviazione mi ha insegnato qualcosa, ma è arrivare qui che dà senso a tutto il resto.

Ringrazio la Prof.ssa Maria Ilaria Lunesu e il Prof. Andrea Pinna per avermi seguito nel corso del tirocinio e nel percorso di tesi, per la disponibilità mostrata e per i consigli che hanno guidato l'evoluzione del lavoro.

Un ringraziamento particolare va alla Dott.ssa Maura Pilia e al Dott. Alessandro Cabras dell'Osservatorio Astronomico di Cagliari e al Dott. Vishal Gajjar del Berkeley SETI Research Center, per il ruolo di riferimento tecnico avuto durante il tirocinio e per il confronto scientifico che ha reso questo lavoro possibile.

L'ultimo pensiero va alla mia famiglia, che non ha mai smesso di credere in questo ritorno agli studi, e agli amici che sono rimasti anche quando la strada era meno chiara.